

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

Ước tính nồng độ bụi mịn PM2.5 mặt đất từ dữ liệu vệ tinh và khí tượng sử dụng học máy

NGUYỄN TÀI KHOA

Khoa.NT215066@sis.hust.edu.vn

Chương trình đào tạo: Công nghệ thông tin Việt-Nhật

Giảng viên hướng dẫn: TS. Trần Nguyên Ngọc

Khoa: Kỹ thuật máy tính

Trường: Công nghệ Thông tin và Truyền thông

HÀ NỘI, 07/2026

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

Ước tính nồng độ bụi mịn PM2.5 mặt đất từ dữ liệu vệ tinh và khí tượng sử dụng học máy

NGUYỄN TÀI KHOA

Khoa.NT215066@sis.hust.edu.vn

Chương trình đào tạo: Công nghệ thông tin Việt-Nhật

Giảng viên hướng dẫn: TS. Trần Nguyên Ngọc

Chữ kí GVHD

Khoa:

Kỹ thuật máy tính

Trường:

Công nghệ Thông tin và Truyền thông

HÀ NỘI, 07/2026

LỜI CẢM ƠN

Tác giả xin gửi lời cảm ơn chân thành đến giảng viên hướng dẫn, TS. Trần Nguyên Ngọc, vì sự hướng dẫn và góp ý trong quá trình thực hiện đồ án. Tác giả cũng xin cảm ơn các thầy cô và cán bộ Trường Công nghệ Thông tin và Truyền thông, Đại học Bách khoa Hà Nội, đã hỗ trợ trong quá trình học tập và hoàn thành đồ án.

Tác giả cảm ơn các đơn vị vận hành mạng quan trắc và mạng cảm biến chi phí thấp đã cung cấp dữ liệu thực địa cho nghiên cứu này. Cuối cùng, tác giả xin cảm ơn gia đình, bạn bè và đồng nghiệp đã động viên và hỗ trợ trong suốt quá trình thực hiện đồ án.

TÓM TẮT NỘI DUNG ĐỒ ÁN

Đồ án nghiên cứu bài toán ước tính PM2.5 mặt đất tại Việt Nam từ dữ liệu vệ tinh, khí tượng và trạm quan trắc. Mục tiêu chính là đánh giá khả năng dự báo tại vị trí chưa có trạm, nơi mức nền ô nhiễm không được biết trước.

Nghiên cứu xây dựng bộ dữ liệu hợp nhất, gồm PM2.5 mặt đất, AOD, khí vết TROPOMI, khí tượng ERA5, mưa, đặc trưng tính và thông tin trạm lân cận. Quy trình kiểm soát chất lượng loại các chuỗi PM2.5 bất thường. Thử nghiệm toàn quốc cho thấy mô hình học tốt dao động theo thời gian tại trạm đã biết, nhưng giảm mạnh khi đánh giá bằng giao thức bỏ một trạm ra. Kết quả này cho thấy mức nền ô nhiễm của vị trí mới vẫn khó suy ra từ các đặc trưng quan sát được.

Từ chẩn đoán đó, đồ án tập trung vào mô hình vùng đồng bằng sông Hồng. Mô hình cuối là XGBoost `gbtree`, dùng base margin theo vùng, đặc trưng vệ tinh và thời tiết, cùng RFSI từ PM2.5 đồng thời tại các trạm lân cận. Trong đánh giá bỏ một trạm ra trên 12 trạm KK, cấu hình `delta_rfsi_wind` đạt R^2 gộp 0,4233 theo giờ và 0,4911 theo ngày. Kiểm định ngoài dùng đặc trưng trích xuất tại đúng tọa độ trạm đạt R^2 0,629 theo giờ và 0,749 theo ngày tại trạm Đại sứ quán Hoa Kỳ ở Hà Nội; trung vị R^2 trên 41 trạm LCS đạt 0,189 theo giờ và 0,155 theo ngày.

Đóng góp chính của đồ án là bộ dữ liệu PM2.5 đa nguồn đã làm sạch, phân tích giới hạn của dự báo toàn quốc theo LOSO, và một mô hình vùng có điều kiện triển khai rõ ràng cho đồng bằng sông Hồng.

Từ khóa: PM2.5, AOD, viễn thám, học máy, XGBoost, RFSI, đồng bằng sông Hồng, cảm biến chi phí thấp

Sinh viên thực hiện

(Ký và ghi rõ họ tên)

Nguyễn Tài Khoa

ABSTRACT

PM2.5 pollution is an important air-quality problem in Vietnam, especially in northern Vietnam during winter periods with weak dispersion. Continuous PM2.5 monitoring is sparse and unevenly distributed, so estimating PM2.5 at unmonitored locations is difficult.

This thesis builds a unified dataset combining ground PM2.5, satellite AOD, TROPOMI trace gases, ERA5 meteorology, precipitation, static features, and nearby-station information. A row-level quality-control mask removes abnormal PM2.5 sequences such as zero runs, flatline runs, and long low-value stuck periods. Nationwide experiments are used as a diagnostic stage. The model learns temporal variation well at stations represented in training, but performance drops sharply under leave-one-station-out evaluation. This indicates that the baseline pollution level of a new location is not reliably identified by the available observable predictors. AOD and trace gases are useful, but hourly AOD is sparse and cannot replace ground observations.

Based on this diagnosis, the final case study focuses on the Red River Delta. The final model is an XGBoost `gbtree` model with a regional base margin, satellite and meteorological features, and RFSI features derived from concurrent PM2.5 observations at nearby monitoring stations. In leave-one-station-out evaluation over 12 regional KK stations, `delta_rfsi_wind` obtains hourly pooled R^2 of 0.4233 and daily pooled R^2 of 0.4911; mean station-level R^2 is 0.2709 hourly and 0.2835 daily. External validation uses features extracted at each target's own coordinates and RFSI from the KK anchor network. It performs well at the US Embassy monitor in Hanoi, with hourly R^2 of 0.629 and daily R^2 of 0.749. Across 41 regional low-cost-sensor stations, median R^2 is 0.189 hourly and 0.155 daily, showing useful but uneven transfer.

The final contribution is a conditional regional model: hourly PM2.5 estimation in the Red River Delta when concurrent PM2.5 from nearby anchor stations is available. Future work should turn this into an operational grid-mapping pipeline and improve estimation of baseline pollution at new locations.

Keywords: PM2.5, AOD, remote sensing, machine learning, XGBoost, RFSI, Red River Delta, low-cost sensors

MỤC LỤC

Lời cảm ơn

Tóm tắt nội dung

Abstract

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI.....	1
1.1 Vấn đề nghiên cứu	1
1.2 Mục tiêu	2
1.3 Đóng góp	2
1.4 Phạm vi triển khai.....	2
1.5 Bố cục đồ án	3
1.6 Kết luận chương	3
CHƯƠNG 2. NỀN TẢNG LÝ THUYẾT	4
2.1 PM2.5 và ý nghĩa sức khỏe	4
2.2 AOD và quan hệ với PM2.5 mặt đất.....	4
2.3 Vai trò của thời tiết	5
2.4 Khí vết và nguồn phát thải	5
2.5 Đánh giá mô hình: tại trạm đã biết và bỏ một trạm ra	5
2.6 RFSI và mô hình có trạm neo.....	7
2.7 Khoảng trống nghiên cứu trong bối cảnh Việt Nam.....	7
2.8 Hàm ý đối với thiết kế phương pháp	8
2.9 Kết luận chương	8
CHƯƠNG 3. DỮ LIỆU VÀ PHƯƠNG PHÁP.....	9
3.1 Tổng quan quy trình	9
3.2 Bộ dữ liệu PM2.5	10
3.3 Lọc chất lượng PM2.5	11

3.4 Độ phủ đặc trưng trong dữ liệu.....	11
3.5 Nhóm đặc trưng.....	13
3.6 Mô hình.....	16
3.7 Đánh giá.....	17
3.8 Kết luận chương	17
CHƯƠNG 4. CHẨN ĐOÁN TOÀN QUỐC VÀ CHỌN VÙNG	18
4.1 Chất lượng dữ liệu sau QC.....	18
4.2 Trạng thái đặc trưng trong dữ liệu thật	18
4.3 AOD có tín hiệu nhưng không đủ ở thang giờ.....	20
4.4 Sản phẩm PM2.5 toàn cầu chưa đủ tốt ở cấp trạm giờ.....	20
4.5 Dữ liệu có học được dao động theo thời gian tại trạm đã biết	21
4.6 Đánh giá bỏ một trạm ra toàn quốc yếu hơn nhiều.....	21
4.7 Bài học từ chia theo địa lý và mức nền.....	22
4.8 Vì sao chọn đồng bằng sông Hồng	22
4.9 Kết luận chương	23
CHƯƠNG 5. THÍ NGHIỆM VÙNG ĐỒNG BẰNG SÔNG HỒNG.....	24
5.1 Thiết lập thí nghiệm.....	24
5.2 Kết quả nội bộ theo giờ	24
5.3 Kết quả theo ngày	27
5.4 Kết quả theo mức ô nhiễm	27
5.5 Vai trò của các nhóm đặc trưng	27
5.6 Kiểm định ngoài bằng LCS và trạm Đại sứ quán Hoa Kỳ.....	29
5.7 Trường hợp thất bại.....	31
5.8 Kết luận chương	32
CHƯƠNG 6. KẾT LUẬN	33
6.1 Kết quả chính	33

6.2 Ý nghĩa của kết quả	33
6.3 Giới hạn.....	34
6.4 Hướng phát triển.....	34
6.5 Kết luận chung	35
TÀI LIỆU THAM KHẢO.....	36
PHỤ LỤC.....	40
A. DỮ LIỆU VÀ ĐẶC TRƯNG	40
A.1 Danh sách trạm quan trắc.....	40
A.2 Các cột nền trong bảng hợp nhất	42
A.3 Đặc trưng RFSI sinh trong từng fold	44
A.4 Google Earth Engine scripts	45
B. CẤU HÌNH THÍ NGHIỆM.....	46
B.1 Môi trường tái lập	46

DANH MỤC HÌNH VẼ

Hình 3.1	Quy trình dữ liệu và mô hình vùng đồng bằng sông Hồng. . .	10
Hình 4.1	So sánh bối cảnh toàn quốc sau lọc và đồng bằng sông Hồng. .	23
Hình 5.1	So sánh hiệu năng các cấu hình vùng đồng bằng sông Hồng. .	26
Hình 5.2	So sánh R^2 theo từng trạm trong LOSO vùng đồng bằng sông Hồng.	26
Hình 5.3	Tỷ lệ gain theo nhóm đặc trưng trong các cấu hình vùng. . .	29
Hình 5.4	Phân bố R^2 theo giờ trên mạng kiểm định ngoài.	30
Hình 5.5	Một số trường hợp thất bại trong kiểm định LCS ngoài. . . .	32

DANH MỤC BẢNG BIỂU

Bảng 2.1	Một số nghiên cứu PM2.5 liên quan và điểm cần chú ý khi so sánh.	6
Bảng 3.1	Độ phủ của một số nhóm đặc trưng chính trong bảng hợp nhất.	12
Bảng 3.2	Thông số chính của pipeline cuối.	14
Bảng 4.1	Một số con số độ phủ quan trọng trong dữ liệu.	19
Bảng 4.2	Chẩn đoán mô hình toàn quốc dưới giao thức bỏ một trạm ra. .	21
Bảng 5.1	Kết quả bỏ một trạm ra theo giờ trên 12 trạm đồng bằng sông Hồng.	25
Bảng 5.2	Kết quả bỏ một trạm ra theo ngày trên 12 trạm đồng bằng sông Hồng.	27
Bảng 5.3	Gain theo nhóm đặc trưng trong ba cấu hình chính.	28
Bảng 5.4	Gain theo nhóm đặc trưng trong mô hình cuối.	28
Bảng 5.5	Kiểm định ngoài trong vùng.	30
Bảng A.1	Danh sách trạm KK trong tập phát triển	40
Bảng A.2	Các cột nền trong bảng hợp nhất	42
Bảng A.3	Đặc trưng RFSI dùng trong mô hình vùng	45
Bảng B.1	Chuỗi script chính của đề án	46

DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT

Thuật ngữ	Ý nghĩa
AHI	Thiết bị chụp ảnh Himawari tiên tiến (Advanced Himawari Imager)
AOD	Độ sâu quang học sol khí (Aerosol Optical Depth)
CEM	Hệ thống quan trắc phát thải liên tục (Continuous Emission Monitoring)
DEM	Mô hình số độ cao (Digital Elevation Model)
ERA5	Bộ dữ liệu tái phân tích khí tượng thế hệ thứ 5 của ECMWF
GEE	Nền tảng phân tích dữ liệu địa không gian của Google (Google Earth Engine)
GEOS-CF	Hệ thống quan sát Trái Đất Goddard – Dự báo thành phần khí quyển (Goddard Earth Observing System – Composition Forecasting)
GPM	Sứ mệnh đo lường mưa toàn cầu (Global Precipitation Measurement)
IMERG	Ước tính mưa tích hợp đa vệ tinh (Integrated Multi-satellitE Retrievals for GPM)
KK	Nhóm trạm quan trắc chất lượng không khí tự động dùng làm tập phát triển và trạm neo trong đồ án
LCS	Cảm biến chi phí thấp (Low-Cost Sensor)
LOSO	Kiểm định chéo bỏ-một-trạm-ra (Leave-One-Station-Out)
LST	Nhiệt độ bề mặt đất (Land Surface Temperature)
MAE	Sai số tuyệt đối trung bình (Mean Absolute Error)
MAIAC	Thuật toán nghịch đảo đa góc cho khí quyển (Multi-Angle Implementation of Atmospheric Correction)
MERRA-2	Tái phân tích khí quyển hiện đại thế hệ 2 (Modern-Era Retrospective analysis for Research and Applications, Version 2)
MODIS	Thiết bị chụp ảnh quang phổ phân giải trung bình (Moderate Resolution Imaging Spectroradiometer)
PBLH	Chiều cao lớp biên hành tinh (Planetary Boundary Layer Height)

Thuật ngữ	Ý nghĩa
PM2.5	Bụi mịn có đường kính khí động học nhỏ hơn 2,5 μm (Particulate Matter $\leq 2.5 \mu\text{m}$)
R ²	Hệ số xác định (Coefficient of Determination)
RFSI	Nhóm đặc trưng không gian từ PM2.5 của trạm neo lân cận; trong pipeline này không phải một thuật toán nội suy riêng
RMSE	Sai số trung bình bình phương gốc (Root Mean Square Error)
TROPOMI	Thiết bị quan trắc tầng đối lưu (TROPOspheric Monitoring Instrument)
XGBoost	Thuật toán tăng cường gradient cực đại (Extreme Gradient Boosting)

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

Ô nhiễm không khí là một vấn đề sức khỏe và môi trường lớn ở Việt Nam. Trong các chất ô nhiễm không khí, PM2.5 đặc biệt đáng chú ý vì hạt nhỏ có thể đi sâu vào hệ hô hấp và liên quan đến nhiều tác động sức khỏe như bệnh tim mạch, bệnh hô hấp và tử vong sớm [1], [2]. Các báo cáo chất lượng không khí gần đây cho thấy Hà Nội và nhiều đô thị miền Bắc thường nằm trong nhóm có PM2.5 cao [3]. Về mặt vật lý, các giai đoạn lớp biên thấp, gió yếu và điều kiện khuếch tán kém có thể làm PM2.5 tích tụ gần mặt đất; cơ chế này được trình bày thêm ở Chương 2.

Để quản lý chất lượng không khí, chỉ biết PM2.5 tại vài trạm là chưa đủ. Người dân và cơ quan quản lý cần thông tin theo không gian và theo thời gian. Tuy nhiên, mạng trạm tự động ở Việt Nam còn thưa và không đều, dù kế hoạch mở rộng mạng quan trắc đang được đặt ra ở cấp quốc gia [4]. Một số vùng có trạm gần nhau, trong khi nhiều nơi chỉ có rất ít hoặc không có trạm PM2.5 liên tục. Vì vậy, câu hỏi đặt ra là: có thể kết hợp dữ liệu mặt đất, vệ tinh và thời tiết để ước tính PM2.5 ở các vị trí không có trạm hay không?

1.1 Vấn đề nghiên cứu

Vệ tinh cung cấp AOD, khí vết, nhiệt độ bề mặt, ánh sáng đêm và nhiều chỉ dấu liên quan đến nguồn phát thải [5], [6], [7]. Dữ liệu tái phân tích cung cấp gió, độ ẩm, nhiệt độ, áp suất, mưa và lớp biên khí quyển [8], [9]. Các nguồn này phủ rộng hơn mạng trạm mặt đất, nên rất hấp dẫn cho bài toán lập bản đồ PM2.5.

Tuy nhiên, bài toán không đơn giản. AOD đo lượng sol khí trong toàn cột khí quyển, còn PM2.5 là nồng độ gần mặt đất. Mối liên hệ giữa hai đại lượng phụ thuộc vào lớp biên, độ ẩm, mây, nguồn phát thải và mùa, nên nhiều nghiên cứu phải kết hợp AOD với khí tượng và đặc trưng không gian thay vì dùng AOD đơn lẻ [10], [11], [12]. Ngoài ra, các trạm khác nhau có mức nền ô nhiễm rất khác nhau. Một mô hình có thể học tốt dao động PM2.5 tại trạm đã biết, nhưng vẫn thất bại khi phải dự đoán cho một trạm hoàn toàn chưa dùng khi huấn luyện.

Đề án này đánh giá cả độ chính xác, nguồn gốc của độ chính xác, khả năng giữ kết quả khi bỏ cả trạm ra và phạm vi triển khai phù hợp của mô hình.

Trong bối cảnh lập bản đồ, chỉ số gộp trên toàn bộ tập kiểm tra không đủ. Một số trạm ô nhiễm cao có phương sai lớn có thể kéo R^2 gộp lên, trong khi nhiều vị trí khác vẫn dự đoán kém. Vì vậy, đề án báo cáo cả chỉ số gộp và chỉ số theo trạm. Kết quả toàn quốc được dùng để chẩn đoán giới hạn của bài toán, còn kết quả cuối tập trung vào đồng bằng sông Hồng, nơi phạm vi triển khai rõ hơn và trạm neo gần

hơn khi xét ba trạm gần nhất.

1.2 Mục tiêu

Mục tiêu của đề án gồm ba phần.

Thứ nhất, xây dựng một bộ dữ liệu hợp nhất cho PM2.5 tại Việt Nam, gồm PM2.5 mặt đất, vệ tinh, thời tiết, mưa, khí vết và đặc trưng tỉnh.

Thứ hai, đánh giá trung thực khoảng cách giữa hai bài toán: dự đoán tại trạm đã biết và dự đoán cho trạm bị giữ lại hoàn toàn. Phần này dùng phạm vi toàn quốc như một nền chẩn đoán.

Thứ ba, xây dựng một mô hình vùng đồng bằng sông Hồng có thể triển khai có điều kiện. Mô hình này ước tính PM2.5 tại một vị trí mục tiêu trong vùng khi có PM2.5 đồng thời từ các trạm neo lân cận.

1.3 Đóng góp

Đề án có bốn đóng góp chính.

1. Xây dựng bộ dữ liệu hợp nhất gồm PM2.5, vệ tinh, thời tiết, mưa, khí vết và đặc trưng tỉnh, kèm quy trình lọc các chuỗi quan trắc PM2.5 bất thường.
2. Chẩn đoán giới hạn của mô hình toàn quốc bằng cách so sánh đánh giá tại trạm đã biết với đánh giá bỏ một trạm ra.
3. Đề xuất mô hình vùng đồng bằng sông Hồng dùng XGBoost [13], base margin theo vùng, RFSI và RFSI có xét hướng gió.
4. Kiểm định mô hình vùng bằng đánh giá nội bộ bỏ một trạm ra và kiểm định ngoài trên mạng LCS cùng trạm Đại sứ quán Hoa Kỳ tại Hà Nội.

1.4 Phạm vi triển khai

Phạm vi triển khai là ước tính PM2.5 theo giờ tại các vị trí trong đồng bằng sông Hồng, sử dụng PM2.5 đồng thời từ các trạm neo lân cận kết hợp với đặc trưng vệ tinh, khí tượng và chu kỳ thời gian. Mô hình dùng ba nhóm thông tin: (i) PM2.5 từ các trạm neo lân cận tại cùng thời điểm; (ii) vệ tinh và khí vết để nhận bối cảnh sol khí và nguồn phát thải; và (iii) thời tiết và chu kỳ thời gian để theo dõi điều kiện tích tụ hoặc khuếch tán.

Vì vậy, mô hình phù hợp cho kịch bản có mạng trạm đang hoạt động và cần ước tính tại các vị trí giữa các trạm. Nếu một khu vực không có trạm neo gần hoặc có bối cảnh ô nhiễm khác hẳn mạng huấn luyện, độ tin cậy sẽ thấp hơn.

1.5 Bố cục đồ án

Chương 2 trình bày nền tảng về PM2.5, AOD, thời tiết, vệ tinh và cách đánh giá mô hình PM2.5.

Chương 3 mô tả dữ liệu và phương pháp, gồm QC, nhóm đặc trưng, RFSI, mô hình XGBoost và các giao thức đánh giá.

Chương 4 chẩn đoán kết quả toàn quốc và giải thích vì sao đồ án chọn đồng bằng sông Hồng làm phạm vi cuối.

Chương 5 trình bày thí nghiệm đồng bằng sông Hồng, gồm đánh giá nội bộ, kết quả theo ngày, gain theo nhóm đặc trưng và kiểm định ngoài.

Chương 6 tổng kết đóng góp, giới hạn và hướng phát triển.

1.6 Kết luận chương

Chương này đã nêu vấn đề nghiên cứu, mục tiêu và phạm vi triển khai của đồ án. Kết quả cuối được định nghĩa là một mô hình vùng đồng bằng sông Hồng, dùng được khi có dữ liệu PM2.5 đồng thời từ các trạm neo lân cận.

CHƯƠNG 2. NỀN TẢNG LÝ THUYẾT

Chương này trình bày các khái niệm cần thiết để hiểu bài toán ước tính PM2.5 từ dữ liệu vệ tinh, thời tiết và trạm mặt đất. Nội dung tập trung vào cơ chế khiến bài toán khó và lý do đánh giá bỏ một trạm ra phù hợp với mục tiêu triển khai.

2.1 PM2.5 và ý nghĩa sức khỏe

PM2.5 là bụi mịn có đường kính khí động học nhỏ hơn hoặc bằng 2,5 micromet. Do kích thước nhỏ, PM2.5 có thể đi sâu vào phổi và liên quan đến nhiều tác động xấu tới sức khỏe [1], [2]. PM2.5 cũng là chỉ số quan trọng trong quản lý chất lượng không khí đô thị vì nó phản ánh nhiều nguồn phát thải khác nhau: giao thông, công nghiệp, đốt sinh khối, bụi thứ cấp và vận chuyển từ vùng khác.

PM2.5 biến đổi theo nhiều thang thời gian. Theo giờ, nó chịu ảnh hưởng của giao thông, hoạt động nguồn thải, gió và lớp biên khí quyển. Theo ngày và theo mùa, nó chịu ảnh hưởng của thời tiết, mưa, độ ẩm, nguồn phát thải theo mùa và vận chuyển vùng. Vì vậy, mô hình PM2.5 phải học cả dao động ngắn hạn và mức nền dài hơn.

2.2 AOD và quan hệ với PM2.5 mặt đất

AOD là độ dày quang học sol khí, đo lượng hạt trong toàn cột khí quyển. Đây là nguồn thông tin vệ tinh quan trọng nhất cho PM2.5, vì PM2.5 cũng là một phần của sol khí. Đồ án này dùng hai nguồn AOD bổ sung nhau về thang thời gian. Vệ tinh địa tĩnh Himawari (AHI) cho AOD theo giờ, phù hợp với bài toán theo giờ nhưng vẫn thừa do mây [14]. Sản phẩm MAIAC MODIS từ vệ tinh cực cho AOD theo ngày với độ phân giải không gian cao hơn nhiều sản phẩm aerosol cổ điển [5], [15]. Tuy nhiên cả hai đều không đo trực tiếp PM2.5 gần mặt đất.

Có ba lý do chính làm quan hệ AOD và PM2.5 phức tạp.

Thứ nhất, AOD là đại lượng theo cột, còn PM2.5 là đại lượng gần mặt đất. Nếu lớp biên khí quyển cao, cùng một lượng hạt có thể bị pha loãng trong một thể tích lớn hơn, làm PM2.5 mặt đất thấp hơn. Nếu lớp biên thấp, PM2.5 có thể tích tụ gần mặt đất. Vì vậy, các mô hình PM2.5 hiện đại thường dùng thêm PBLH, độ ẩm và các biến khí tượng để nối AOD với PM2.5 bề mặt [10], [11].

Thứ hai, độ ẩm làm hạt hút nước và tán xạ ánh sáng mạnh hơn. Khi độ ẩm cao, AOD có thể tăng ngay cả khi khối lượng PM2.5 khô không tăng tương ứng.

Thứ ba, AOD bị thiếu khi có mây và bị ảnh hưởng bởi thuật toán truy xuất. Ở khí hậu nhiệt đới gió mùa, thiếu dữ liệu AOD là vấn đề thường xuyên. Vì vậy, AOD

có ích nhưng không đủ để dự đoán PM2.5 theo giờ nếu đứng một mình.

2.3 Vai trò của thời tiết

Thời tiết quyết định cách chất ô nhiễm tích tụ hoặc khuếch tán. Lớp biên thấp, gió yếu và không mưa thường làm PM2.5 tăng. Gió mạnh và mưa thường làm PM2.5 giảm. Độ ẩm vừa ảnh hưởng đến bản thân hạt, vừa ảnh hưởng đến quan hệ giữa AOD và PM2.5. Trong đồ án này, phần khí tượng chủ yếu lấy từ ERA5 và mưa từ GPM IMERG [8], [9].

Ở miền Bắc Việt Nam, mùa đông thường có nhiều đợt PM2.5 cao do lớp biên thấp và điều kiện khuếch tán kém. Vì vậy, các biến như PBLH, gió, độ ẩm, nhiệt độ, mưa, số giờ khô và chu kỳ mùa là những đặc trưng cần thiết trong mô hình.

2.4 Khí vết và nguồn phát thải

Các khí vết từ TROPOMI như NO₂, SO₂, CO và HCHO (formaldehyde) không phải PM2.5, nhưng chúng giúp mô hình nhận bối cảnh nguồn phát thải. NO₂ thường liên quan đến giao thông và đốt nhiên liệu. SO₂ có thể liên quan đến công nghiệp và nhiệt điện. CO thường liên quan đến đốt cháy. HCHO có liên hệ với quá trình quang hóa và nguồn hữu cơ. Các sản phẩm Sentinel-5P/TROPOMI cung cấp nguồn thông tin này trên diện rộng, nhưng vẫn có độ nhiễu, độ phủ và độ phân giải riêng [6].

Các khí vết này có độ phân giải và độ nhiễu riêng, nên không thể tự quyết định PM2.5 tại một điểm nhỏ. Vai trò hợp lý của chúng là bổ sung thông tin về bối cảnh nguồn phát thải cho AOD, thời tiết và trạm neo.

2.5 Đánh giá mô hình: tại trạm đã biết và bỏ một trạm ra

Các nghiên cứu quốc tế khác nhau về mật độ trạm, thang thời gian, biến đầu vào và giao thức đánh giá, nên chỉ số R^2 không thể so sánh trực tiếp giữa các nghiên cứu [10], [11], [16]. Khi chia mẫu ngẫu nhiên, dữ liệu của cùng một trạm có thể xuất hiện ở cả tập huấn luyện và tập kiểm tra. Khi đó mô hình đã biết phần nào mức nền, chu kỳ và đặc điểm riêng của trạm. Kết quả này trả lời câu hỏi: mô hình có học được các giờ bị thiếu tại trạm đã biết hay không?

Bài toán triển khai khó hơn là dự đoán cho một vị trí chưa từng có trong huấn luyện. Để đo điều này, cần đánh giá bỏ một trạm ra. Trong giao thức này, toàn bộ chuỗi của một trạm bị giữ lại, và mô hình chỉ học từ các trạm khác. Đây là cách kiểm tra sát hơn với bài toán lập bản đồ tại vị trí mới.

Hai giao thức này không thay thế nhau. Đánh giá tại trạm đã biết cho biết dữ liệu có tín hiệu thời gian hay không. Đánh giá bỏ một trạm ra cho biết mô hình có suy ra được bối cảnh không gian của vị trí mới hay không.

Bảng 2.1: Một số nghiên cứu PM2.5 liên quan và điểm cần chú ý khi so sánh.

Nghiên cứu	Khu vực	Thang thời gian	Dữ liệu chính	Giao thức và ý nghĩa
Di et al. [10]	Hoa Kỳ	Ngày	AOD, khí tượng, sử dụng đất, mô hình tổ hợp	Mạng trạm dày và dữ liệu phụ trợ mạnh; kết quả cao không thể chuyển thẳng sang bối cảnh ít trạm
Wei et al. [11]	Trung Quốc	Ngày, 1 km	MAIAC AOD, khí tượng, sử dụng đất, học máy cây	Cho thấy AOD và khí tượng rất hữu ích ở quy mô ngày, nhưng không giải quyết trực tiếp bài toán theo giờ
Chen et al. [16]	Châu Âu	Ngày	AOD, khí tượng, không gian, sử dụng đất	Nhấn mạnh vai trò của đặc trưng không gian và giao thức kiểm định
Gupta et al. [17]	Thái Lan	Ngày	Vệ tinh, khí tượng, học máy	Gần bối cảnh Đông Nam Á hơn, nhưng vẫn khác về mạng trạm và độ phủ dữ liệu
Ngo et al. [12]	Việt Nam	Ngày	Quan sát không gian và dữ liệu phụ trợ	Cung cấp nền dữ liệu PM2.5 ngày cho Việt Nam; đồ án này tập trung thêm vào dữ liệu theo giờ và đánh giá bỏ cả trạm ra

Bảng 2.1 (tiếp)

Nghiên cứu	Khu vực	Thang thời gian	Dữ liệu chính	Giao thức và ý nghĩa
Đồ án này	Việt Nam, ĐBSH	Giờ và ngày	PM2.5 trạm, AOD, TROPOMI, ERA5, GPM, trạm neo	Tách rõ đánh giá trong trạm, LOSO toàn quốc và mô hình vùng có điều kiện triển khai

2.6 RFSI và mô hình có trạm neo

Trong đồ án này, RFSI là tên ngắn cho nhóm đặc trưng không gian từ trạm neo, không phải một thuật toán nội suy riêng. Nhóm này đưa thông tin từ các trạm lân cận vào mô hình. Thay vì chỉ dùng khoảng cách, RFSI dùng PM2.5 đo được tại các trạm neo cùng thời điểm, ví dụ PM2.5 của trạm gần nhất, trung bình có trọng số theo khoảng cách, hoặc PM2.5 phía đầu gió.

RFSI có ý nghĩa thực tế rõ: nếu một mạng trạm đang hoạt động, các điểm giữa các trạm có thể được ước tính tốt hơn khi biết PM2.5 ở trạm lân cận. Nhưng nó cũng đặt ra điều kiện triển khai. Mô hình không còn là mô hình chỉ dựa vào vệ tinh. Nó cần dữ liệu mặt đất đồng thời từ mạng trạm neo.

Trạm mục tiêu không bao giờ được dùng làm trạm neo trong đánh giá bỏ một trạm ra.

2.7 Khoảng trống nghiên cứu trong bối cảnh Việt Nam

Các kết quả quốc tế cần được đọc trong bối cảnh mật độ trạm, thang thời gian, biến đầu vào và giao thức đánh giá của từng nghiên cứu [10], [11], [17]. Ở Việt Nam đã có các bộ dữ liệu PM2.5 ngày từ quan sát không gian, nhưng bài toán theo giờ và bỏ toàn bộ trạm ra vẫn khó hơn [12]. Việt Nam có mạng trạm tự động còn thưa và không đều, trong khi điều kiện thời tiết nhiệt đới làm AOD bị thiếu và nhiễu.

Trong bối cảnh này, một đánh giá phù hợp cần tách rõ hai loại năng lực. Năng lực thứ nhất là học dao động PM2.5 theo thời gian tại trạm đã có trong huấn luyện. Năng lực thứ hai là chuyển giao sang một vị trí chưa từng xuất hiện trong huấn luyện. Hai năng lực này liên quan nhưng không tương đương, vì vị trí mới có thể có mức nền ô nhiễm, nguồn phát thải và quan hệ với trạm lân cận khác với các trạm đã biết.

2.8 Hàm ý đối với thiết kế phương pháp

Các cơ sở trên dẫn đến ba yêu cầu phương pháp.

Thứ nhất, mô hình cần kết hợp dữ liệu vệ tinh với khí tượng và chu kỳ thời gian. AOD cung cấp tín hiệu aerosol trên diện rộng, khí vết bổ sung bối cảnh nguồn phát thải, còn PBLH, gió, mưa, độ ẩm và mùa giúp mô hình theo dõi điều kiện tích tụ hoặc khuếch tán gần mặt đất.

Thứ hai, giao thức đánh giá phải bao gồm LOSO. Chia mẫu ngẫu nhiên hoặc KFold trong từng trạm cho biết dữ liệu có tín hiệu thời gian hay không. LOSO kiểm tra thêm khả năng suy ra bối cảnh của một trạm hoàn toàn bị giữ lại. Vì vậy, hai giao thức được báo cáo riêng.

Thứ ba, các đặc trưng từ trạm neo phải được tạo theo đúng fold đánh giá. Trong LOSO, PM2.5 của trạm mục tiêu không được dùng để tạo RFSI, base margin hoặc bất kỳ đặc trưng nào của chính fold đó. Cách làm này giữ vai trò của trạm neo như một nguồn thông tin vận hành, đồng thời tránh rò rỉ PM2.5 của vị trí mục tiêu vào tập huấn luyện.

2.9 Kết luận chương

Chương này làm rõ ba nền tảng cho phần phương pháp. Thứ nhất, AOD và khí vết có tín hiệu nhưng không đo trực tiếp PM2.5 sát mặt đất. Thứ hai, thời tiết và chu kỳ mùa giúp giải thích dao động theo thời gian. Thứ ba, đánh giá bỏ một trạm ra cần được tách khỏi đánh giá trong trạm, vì hai giao thức trả lời hai câu hỏi khác nhau. Các điểm này là cơ sở cho chẩn đoán toàn quốc ở Chương 4 và mô hình vùng có trạm neo ở Chương 5.

CHƯƠNG 3. DỮ LIỆU VÀ PHƯƠNG PHÁP


Chương này mô tả bộ dữ liệu, quy trình kiểm soát chất lượng, cách tạo đặc trưng và giao thức đánh giá. Phạm vi triển khai chính là ước tính PM2.5 theo giờ trong đồng bằng sông Hồng khi có dữ liệu PM2.5 đồng thời từ các trạm neo lân cận. Mô hình kết hợp thông tin trạm neo với vệ tinh, thời tiết, khí vết và chu kỳ thời gian để ước tính PM2.5 tại một vị trí mục tiêu trong vùng.

3.1 Tổng quan quy trình

Quy trình gồm năm bước chính.

1. Thu thập PM2.5 theo giờ từ các trạm mặt đất, gồm 40 trạm KK trong tập phát triển ban đầu và các trạm LCS cùng trạm Đại sứ quán Hoa Kỳ dùng cho kiểm định ngoài.
2. Hợp nhất dữ liệu PM2.5 với các nguồn vệ tinh, thời tiết, mưa, địa hình, mật độ xây dựng và các chỉ dấu nguồn phát thải.
3. Lọc các chuỗi quan trắc PM2.5 bất thường như chuỗi bằng không, chuỗi đứng yên và chuỗi kẹt ở mức rất thấp.
4. Xây dựng đặc trưng theo nhóm: vệ tinh AOD, khí vết TROPOMI, thời tiết, chu kỳ thời gian, đặc trưng tĩnh và PM2.5 từ trạm neo lân cận.
5. Đánh giá theo hai cách: đánh giá tại trạm đã biết và đánh giá bỏ một trạm ra.

Hình 3.1 tóm tắt quy trình từ hợp nhất dữ liệu, lọc QC, tạo đặc trưng, đánh giá toàn quốc đến mô hình vùng cuối.



Hình 3.1: Quy trình dữ liệu và mô hình vùng đồng bằng sông Hồng.

Thí nghiệm vùng sử dụng XGBoost dạng `gbtree`, base margin theo vùng, nhóm đặc trưng RFSI từ trạm neo và RFSI có xét hướng gió [13]. Trong từng fold bỏ một trạm ra, PM2.5 của trạm mục tiêu không được dùng để tạo đặc trưng RFSI cho tập đánh giá. PM2.5 tại vị trí mục tiêu chỉ đóng vai trò biến đáp ứng khi huấn luyện hoặc chấm điểm theo đúng fold.

3.2 Bộ dữ liệu PM2.5

Bảng dữ liệu chính là `unified_thesis.csv`. Đây là bảng hợp nhất cuối cùng của đề án, gồm 121 trạm và dữ liệu theo giờ. Toàn bộ bảng hợp nhất trải từ 2015-01-01 01:00 đến 2026-04-16 20:00, nhưng từng trạm và từng nguồn có thời gian phủ khác nhau. Các thí nghiệm chỉ dùng các timestamp hợp lệ sau khi ghép và lọc QC, không giả định mọi nguồn phủ kín toàn bộ giai đoạn.

Tập phát triển chính dùng 40 trạm KK. Trong đề án này, KK là nhóm trạm quan trắc chất lượng không khí tự động được dùng cho thí nghiệm phát triển mô hình và làm trạm neo. Các thí nghiệm quốc gia dùng đủ 40 trạm này theo giao thức bỏ một

trạm ra, với bộ lọc QC áp dụng ở cấp từng dòng PM2.5. Thí nghiệm đồng bằng sông Hồng dùng 12 trạm KK trong vùng.

Mạng LCS không được dùng để chọn mô hình. Các trạm này được giữ cho kiểm định ngoài, chủ yếu trong vùng phía Bắc và trong khoảng 2025-10 đến 2026-04 tùy trạm. Trạm Đại sứ quán Hoa Kỳ tại Hà Nội, lấy từ chương trình quan trắc của Bộ Ngoại giao Hoa Kỳ, cũng được dùng như một điểm kiểm định ngoài chất lượng cao cho mô hình vùng.

Các tầng ô nhiễm t0, t1, t2 và t3 chỉ dùng cho phân tích chẩn đoán. Chúng được gán từ PM2.5 trung bình sau QC của từng trạm: t0 dưới $10 \mu\text{g}/\text{m}^3$, t1 từ 10 đến dưới $20 \mu\text{g}/\text{m}^3$, t2 từ 20 đến dưới $35 \mu\text{g}/\text{m}^3$, và t3 từ $35 \mu\text{g}/\text{m}^3$ trở lên. Vì cách gán này cần biết PM2.5 thật của trạm mục tiêu, cấu hình `oracle true-tier` trong Chương 4 không triển khai được tại vị trí mới.

3.3 Lọc chất lượng PM2.5

Dữ liệu PM2.5 từ trạm quan trắc tự động và cảm biến ngoài có thể có các lỗi rất đặc trưng. Đồ án dùng bộ lọc ở cấp từng dòng dữ liệu:

- giá trị PM2.5 bằng không hoặc âm;
- chuỗi giá trị đứng yên nhiều giờ liên tiếp;
- chuỗi kẹt ở mức rất thấp trong thời gian dài;
- giá trị quá cao, lớn hơn $500 \mu\text{g}/\text{m}^3$.

Trên 40 trạm KK, bộ lọc mạnh loại 25.093 quan sát trong quá trình xây dựng dữ liệu, tương đương 3,4% số dòng PM2.5 hợp lệ ban đầu. Sau khi lọc, còn 702.542 quan sát dùng cho các thí nghiệm quốc gia. Ở bước chạy mô hình cuối, mask QC không loại thêm dòng nào vì các lỗi chính đã được xử lý trong giai đoạn xây dựng dữ liệu.

Bước này nhằm tránh cho mô hình học các chuỗi quan trắc bất thường như một mẫu ô nhiễm thật. Các dòng bị mask vì dấu hiệu lỗi vận hành hoặc lỗi chuỗi đo vẫn được ghi lại trong báo cáo QC để việc xử lý có thể kiểm tra lại.

3.4 Độ phủ đặc trưng trong dữ liệu

Các nguồn dữ liệu có độ phủ khác nhau. PM2.5, thời tiết và chu kỳ thời gian có thể được đưa về dạng gần như liên tục theo giờ. AOD và một số khí vết bị thiếu nhiều do mây, quỹ đạo vệ tinh, điều kiện truy xuất và chất lượng sản phẩm đầu vào. Vì vậy, mô hình dùng cả giá trị của AOD hoặc khí vết, trạng thái thiếu dữ liệu, thời gian từ lần quan sát AOD gần nhất và các thống kê lân.

Các tỷ lệ phủ trong mục này tính trên toàn bộ bảng hợp nhất 121 trạm; Bảng A.2

ở phụ lục tính riêng trên 40 trạm KK nên cao hơn (ví dụ AOT trung bình quanh trạm 51% thay vì 36%).

Trong bảng hợp nhất, PM2.5 sau ghép có độ phủ khoảng 80,2%. Nhóm thời tiết có độ phủ cao hơn nhiều: PBLH đạt 100%, các biến nhiệt độ, độ ẩm, áp suất, gió và độ che phủ mây đạt khoảng 91,4%, còn các biến mưa tích lũy và số ngày khô đạt 100%. Điều này làm cho thời tiết trở thành nhóm ổn định nhất để học dao động theo giờ.

AOD theo giờ trong đồ án lấy từ vệ tinh địa tĩnh Himawari, nên dù có tần suất quan sát cao vẫn bị thiếu nhiều do mây. Pixel AOT trung tâm chỉ có dữ liệu khoảng 11,4% số giờ. Các thống kê không gian như AOT trung bình quanh trạm có độ phủ cao hơn, khoảng 36,2%, và AOT vùng ngoài khoảng 35,5%. Khi dùng giá trị AOT gần nhất trong 48 giờ, độ phủ tăng lên khoảng 65,9%. Biến `hours_since_valid_AOT` có độ phủ khoảng 90,8% vì nó mô tả tuổi của lần quan sát AOD gần nhất, kể cả khi giờ hiện tại không có AOD mới. AOD theo ngày từ MODIS MAIAC được dùng riêng cho các thống kê lần theo ngày.

Bảng 3.1: Độ phủ của một số nhóm đặc trưng chính trong bảng hợp nhất.

Nhóm	Ví dụ đặc trưng	Độ phủ xấp xỉ	Ý nghĩa với mô hình
PM2.5 mục tiêu	PM2.5 (biến mục tiêu)	80,2%	Dùng để huấn luyện và đánh giá sau QC
Thời tiết	PBLH, nhiệt độ, độ ẩm, áp suất, gió	91,4% đến 100%	Nguồn ổn định để học dao động theo giờ
Mưa và khô hạn	<code>rain_sum_48h</code> , số ngày mưa/khô	100%	Giúp mô hình nhận pha rửa trôi hoặc tích tụ
AOD thô (Himawari)	AOT pixel trung tâm	11,4%	Tín hiệu trực tiếp nhưng rất thưa
AOD theo không gian (Himawari)	<code>AOT_mean</code> , <code>AOT_outer_mean</code>	35% đến 36%	Giảm phụ thuộc vào đúng pixel trạm
AOD lần (Himawari)	<code>AOT_ffill_48h</code> , AOT lần 24h	53% đến 66%	Giữ lại tín hiệu aerosol gần đây
Khí vết TROPOMI	NO2, SO2, CO, HCHO	8% đến 66%	Bổ sung bối cảnh nguồn phát thải
Chu kỳ thời gian	<code>hour_sin/cos</code> , <code>month_sin/cos</code>	100%	Học chu kỳ ngày đêm và mùa

Bảng này giải thích vì sao không thể đọc tầm quan trọng của AOD theo cách đơn giản là "AOD có hoặc không có ích". AOD có ích khi nó xuất hiện, nhất là khi được đặt trong bối cảnh PBLH, độ ẩm và mùa. Nhưng vì AOD thừa, một mô hình dựa chủ yếu vào AOD thô sẽ không ổn định ở thang giờ. Cách dùng phù hợp hơn là kết hợp AOD thô, AOD không gian, AOD lẫn và biến tuổi quan sát AOD.

Đối với vùng đồng bằng sông Hồng, khi lọc còn 227.075 dòng theo giờ, các đặc trưng vệ tinh dạng lẫn vẫn không phủ kín hoàn toàn. MODIS daily ghép được khoảng 58,8% dòng, MODIS rolling khoảng 53,3%, TROPOMI rolling khoảng 59,7%, còn HCHO anomaly khoảng 38,8%. Vệ tinh vì vậy đóng vai trò hỗ trợ trong mô hình vùng, trong khi thông tin trạm neo cung cấp tín hiệu gần mặt đất trực tiếp hơn.

3.5 Nhóm đặc trưng

Các đặc trưng được chia theo nguồn và vai trò.

Về nguồn dữ liệu, PM2.5 mặt đất từ Envisoft/CEM và các file lịch sử được dùng làm biến mục tiêu, dữ liệu huấn luyện và dữ liệu trạm neo. Các biến khí tượng trong mô hình lấy từ ERA5 hoặc nguồn tái phân tích truy cập qua Open-Meteo; khi phụ lục ghi Open-Meteo, đó là kênh truy xuất và chuẩn hóa khí tượng. Các khí vết NO₂, SO₂, CO và HCHO dùng trong mô hình vùng là sản phẩm Sentinel-5P/TROPOMI được xuất qua Google Earth Engine. Mưa lấy từ GPM IMERG. MODIS và Himawari cung cấp AOD; MODIS LST được trích xuất như biến vệ tinh hỗ trợ và kiểm tra nguồn.

Nhóm AOD vệ tinh gồm AOD từ Himawari, MODIS MAIAC, các thống kê lẫn theo ngày và các biến mô tả độ phủ hoặc độ tin cậy của AOD [5], [14], [15]. AOD là tín hiệu quan trọng nhưng thừa, nhất là khi có mây. Vì vậy AOD không được dùng đơn lẻ mà kết hợp với lớp biên khí quyển, độ ẩm và thời tiết.

Nhóm khí vết TROPOMI gồm các chỉ dấu liên quan đến NO₂, SO₂, CO và HCHO [6]. Nhóm này giúp mô hình nhận biết bối cảnh nguồn phát thải, ví dụ khu công nghiệp, giao thông hoặc đốt cháy. Các khí vết không đủ để nhận ra mọi nguồn cục bộ, nhưng chúng có ích khi kết hợp với các biến khác.

Nhóm thời tiết gồm PBLH, gió, nhiệt độ, độ ẩm, áp suất, mưa, số ngày khô và các biến liên quan đến thông gió. Các biến này chủ yếu lấy từ ERA5 và GPM IMERG [8], [9]. Đây là nhóm giúp mô hình theo dõi dao động theo giờ và theo ngày, nhất là trong mùa đông miền Bắc khi lớp biên thấp và gió yếu làm PM2.5 tích tụ.

Nhóm chu kỳ thời gian gồm giờ trong ngày và tháng trong năm dưới dạng sin và

cos. Nhóm này giúp mô hình học chu kỳ ngày đêm và mùa mà không tạo ra điểm gãy nhân tạo giữa 23 giờ và 0 giờ hoặc giữa tháng 12 và tháng 1.

Nhóm tính gồm vĩ độ, độ cao, mật độ xây dựng, ánh sáng đêm và các đặc trưng địa hình hoặc nguồn phát thải ổn định. Các biến này không thay đổi theo giờ, nhưng giúp mô hình hiểu sự khác nhau về bối cảnh giữa các trạm.

Nhóm RFSI là nhóm quan trọng nhất cho mô hình vùng. Trong pipeline này, RFSI là nhóm đặc trưng không gian từ PM2.5 của trạm neo lân cận, không được triển khai như một thuật toán nội suy riêng. Với mỗi dòng dữ liệu, các trạm neo gần nhất trong cùng thời điểm được dùng để tính:

- PM2.5 nội suy theo nghịch đảo khoảng cách;
- PM2.5 của trạm gần thứ nhất, thứ hai và thứ ba;
- PM2.5 phía đầu gió và cuối gió;
- chênh lệch giữa đầu gió và cuối gió;
- độ phân tán PM2.5 giữa các trạm neo.

Gọi d_i là khoảng cách (km) từ vị trí mục tiêu tới trạm neo i có PM2.5 hợp lệ tại cùng thời điểm và p_i là PM2.5 đo được tại trạm đó. Nội suy theo nghịch đảo khoảng cách là $\hat{p}_{idw} = (\sum_i w_i p_i) / (\sum_i w_i)$ với $w_i = 1/d_i$. Với thành phần theo gió, gọi θ_i là phương vị từ mục tiêu tới trạm i và ϕ là hướng gió thổi từ đâu tới, lấy từ $\text{atan2}(-\text{wind}_u, -\text{wind}_v)$; trọng số đầu gió là $w_i^u = \max(\cos(\theta_i - \phi), 0) / \max(d_i, 0.5)$, còn trọng số cuối gió dùng hướng ngược lại $\phi + 180^\circ$. PM2.5 đầu gió $\hat{p}_{up}$ và cuối gió $\hat{p}_{down}$ là trung bình có trọng số tương ứng; chênh lệch đầu–cuối gió là $\hat{p}_{up} - \hat{p}_{down}$ và độ phân tán lân cận là $\max_i p_i - \min_i p_i$.

Trong đánh giá bỏ một trạm ra, trạm bị giữ lại luôn bị loại khỏi nhóm trạm neo. Vì vậy RFSI không dùng PM2.5 của chính trạm mục tiêu.

Bảng 3.2 ghi các thông số cố định của bước QC, RFSI và XGBoost trong pipeline cuối. Các thông số này lấy từ `pm25_qc.py` và `exp_red_river_delta.py`.

Bảng 3.2: Thông số chính của pipeline cuối.

Thành phần	Thông số
QC PM2.5 bằng không hoặc âm	Mask khi PM2.5 ≤ 0
QC giá trị quá cao	Mask khi PM2.5 $> 500 \mu\text{g}/\text{m}^3$

Bảng 3.2 (tiếp)

Thành phần	Thông số
QC flatline	Mask chuỗi ít nhất 5 giờ liên tiếp, sau khi làm tròn PM2.5 đến 1 chữ số thập phân; các điểm trong chuỗi phải cách nhau không quá 1,5 giờ
QC kết mức thấp	Mask chuỗi PM2.5 $\leq 2 \mu\text{g}/\text{m}^3$ kéo dài ít nhất 48 giờ liên tiếp
Số trạm neo RFSI	K_NN = 5; các đặc trưng trực tiếp dùng IDW và ba trạm gần nhất
Khi không đủ 5 trạm neo đồng thời	Dùng các trạm neo có PM2.5 hợp lệ tại timestamp đó; nếu ít hơn 5 trạm hợp lệ thì các cột lân cận còn lại để thiếu và được mô hình xử lý như giá trị thiếu
IDW cơ bản	Trọng số $1/d$, với d là khoảng cách theo km tới trạm neo có PM2.5 tại cùng thời điểm
RFSI theo gió	Tính bearing từ vị trí mục tiêu tới từng trạm neo; hướng gió lấy từ $\text{atan2}(-\text{wind}_u, -\text{wind}_v)$ nên là hướng gió thổi từ đâu tới; trọng số đầu gió và cuối gió là $\max(\cos(\text{delta_angle}), 0) / \max(d, 0.5)$
Spread theo gió	$\text{PM25_wind_spread} = \text{PM25_upwind_idw} - \text{PM25_downwind_idw}$

Bảng 3.2 (tiếp)

Thành phần	Thông số
Spread lân cận	PM25_neighbor_spread = max(PM2.5 neo) - min(PM2.5 neo) tại cùng thời điểm
XGBoost	n_estimators=500, max_depth=4, learning_rate=0.05, subsample=0.8, colsample_bytree=0.6, min_child_weight=50, reg_alpha=0.1, reg_lambda=10, tree_method=hist, random_state=42

HCHO trong Bảng 3.1 là nhóm đặc trưng được tạo downstream từ GEE daily export trong script thí nghiệm vùng, gồm hcho_daily_anom, các thống kê lần 30 ngày và một số tương tác vật lý như hcho_surface. Vì vậy HCHO không nhất thiết xuất hiện như một cột nền riêng trong `feature_list.csv` ở Phụ lục A.

3.6 Mô hình

Mô hình cơ sở là XGBoost `gbtree`. Biến mục tiêu được học trên thang $\log_{1p}$ (PM2.5) để giảm ảnh hưởng của các đợt cực trị, sau đó chuyển ngược về $\mu\text{g}/\text{m}^3$ khi chấm điểm. Base margin cũng được đưa vào trên thang $\log_{1p}$. Trong thí nghiệm đồng bằng sông Hồng, base margin của một fold được tính từ trung bình PM2.5 của các trạm huấn luyện trong vùng, không dùng trạm bị giữ lại.

Các biến thể chính trong thí nghiệm vùng là:

- `delta_bm`: đặc trưng quan sát và vật lý, base margin theo vùng;
- `delta_rfsi`: thêm RFSI từ trạm neo lân cận;
- `delta_rfsi_wind`: thêm RFSI có xét hướng gió;
- `delta_rfsi_regime`: thêm một số đặc trưng đô thị và nguồn phát thải;
- `oracle_bm`: dùng trung bình PM2.5 hậu QC của trạm bị giữ lại theo tháng lịch, gộp toàn bộ các năm, chỉ để đo trần chẩn đoán.

`oracle_bm` không triển khai được tại vị trí mới vì cần biết trước PM2.5 thật của trạm mục tiêu. Cấu hình này chỉ đo mức cải thiện có thể đạt được nếu mức nền theo tháng của vị trí mục tiêu đã được biết.

3.7 Đánh giá

Đồ án dùng ba lớp đánh giá.

Đánh giá tại trạm đã biết dùng 5-fold KFold xáo trộn trong từng trạm. Mục đích là đo xem các đặc trưng có đủ sức học dao động theo giờ khi mô hình đã biết bối cảnh trạm hay không. Script cũng ghi thêm một kiểm tra phụ theo chia thời gian 70/30, nhưng chỉ số chính dùng để so sánh với LOSO là KFold trong trạm. Chẩn đoán này dùng cùng bộ lọc PM2.5 `pm25_quality_masks` với mô hình vùng cuối.

Đánh giá bỏ một trạm ra dùng toàn bộ chuỗi của một trạm làm tập kiểm tra, còn các trạm khác làm tập huấn luyện. Đây là giao thức chính để đo khả năng dự đoán tại trạm chưa dùng khi huấn luyện.

Kiểm định ngoài dùng mạng LCS và trạm Đại sứ quán Hoa Kỳ tại Hà Nội. Các đặc trưng vệ tinh, khí tượng và chu kỳ thời gian của trạm kiểm định được trích xuất tại đúng tọa độ của trạm từ cùng bảng hợp nhất, còn RFSI được tính tại vị trí đó từ mạng trạm neo KK đồng thời. PM2.5 của trạm kiểm định chỉ dùng làm giá trị tham chiếu để chấm điểm, không đưa vào đầu vào. Vì vậy đây là kiểm định chuyển giao tại đúng tọa độ mục tiêu; bước mở rộng thành lập bản đồ vận hành cho mọi điểm lưới được đưa vào hướng phát triển tiếp theo.

Các chỉ số báo cáo gồm R^2 gộp, R^2 trung bình theo trạm, R^2 trung vị theo trạm, tỷ lệ trạm có R^2 dương, RMSE, MAE và bias. Gọi y_i là PM2.5 quan trắc, $\hat{y}_i$ là giá trị dự đoán, $\bar{y}$ là trung bình quan trắc và n là số quan sát. Các chỉ số được định nghĩa như sau: $R^2 = 1 - \sum_i (y_i - \hat{y}_i)^2 / \sum_i (y_i - \bar{y})^2$; $RMSE = \sqrt{\frac{1}{n} \sum_i (\hat{y}_i - y_i)^2}$; $MAE = \frac{1}{n} \sum_i |\hat{y}_i - y_i|$; và $bias = \frac{1}{n} \sum_i (\hat{y}_i - y_i)$. R^2 gộp được tính sau khi ghép tất cả quan sát kiểm tra của các fold. R^2 trung bình theo trạm được tính bằng cách tính R^2 riêng cho từng trạm rồi lấy trung bình. Với kết quả theo ngày, dự đoán theo giờ và PM2.5 quan trắc được lấy trung bình theo ngày; một ngày chỉ được dùng khi có ít nhất 18 giờ hợp lệ. Mô hình ngày không được huấn luyện lại riêng.

3.8 Kết luận chương

Chương này xác định dữ liệu, nguồn đặc trưng, QC và giao thức đánh giá. Mô hình vùng dùng PM2.5 đồng thời từ trạm neo lân cận cùng đặc trưng vệ tinh, khí vết, thời tiết và thời gian. Các chương sau đánh giá hai mức khó: dự đoán tại trạm đã có trong huấn luyện và dự đoán khi giữ trọn một trạm ra ngoài.

CHƯƠNG 4. CHẨN ĐOÁN TOÀN QUỐC VÀ CHỌN VÙNG

Chương này đánh giá khả năng chuyển giao của mô hình toàn quốc dưới các giao thức khác nhau, đồng thời phân tích các yếu tố làm suy giảm hiệu năng khi giữ toàn bộ một trạm ngoài huấn luyện. Các thí nghiệm toàn quốc kiểm tra ba vấn đề: dữ liệu có học được dao động PM2.5 hay không, vệ tinh có đủ tín hiệu hay không, và dự đoán tại một trạm chưa từng dùng khi huấn luyện khác gì so với dự đoán tại trạm đã biết.

Kết luận chính của chương là: mức nền ô nhiễm của từng trạm là một thông tin quan trọng mà các đặc trưng quan sát được trong bộ dữ liệu hiện tại chưa suy ra ổn định cho mọi trạm bị giữ lại. Các đặc trưng như AOD, khí vết, thời tiết và đặc trưng tĩnh có ích, nhưng chưa đủ để nhận ra một cách đáng tin cậy mức nền của mọi vị trí mới. Dựa trên các kết quả này, phần thực nghiệm tiếp theo tập trung vào đồng bằng sông Hồng, nơi ô nhiễm cao, ba trạm neo gần nhất thường gần hơn, và dữ liệu PM2.5 đồng thời từ trạm neo có thể hỗ trợ ước tính theo giờ.

4.1 Chất lượng dữ liệu sau QC

Bước đầu tiên là kiểm tra dữ liệu PM2.5 mặt đất. Bộ lọc QC loại các chuỗi bằng không, chuỗi đứng yên và chuỗi kẹt ở mức rất thấp. Trên 40 trạm KK, 25.093 quan sát bị loại, tương đương 3,4% dữ liệu PM2.5 hợp lệ ban đầu. Sau lọc còn 702.542 quan sát cho các thí nghiệm toàn quốc.

Kiểm tra này có hai ý nghĩa. Thứ nhất, các flatline không còn là nguyên nhân chính của sai số trong thí nghiệm cuối. Thứ hai, nếu một trạm vẫn khó dự đoán sau khi QC, cần đọc đó là vấn đề về thông tin và bối cảnh trạm, không nên vội xem là lỗi vẽ hay lỗi mask.

4.2 Trạng thái đặc trưng trong dữ liệu thật

Dữ liệu đầu vào có độ phủ không đồng đều giữa các nguồn. Bộ dữ liệu được tổ chức theo giờ, trong khi nhiều sản phẩm vệ tinh chỉ có mặt ở một phần số giờ do mây, quỹ đạo bay và điều kiện truy xuất.

Nhóm ổn định nhất là thời tiết và chu kỳ thời gian. PBLH, mưa tích lũy và các biến chu kỳ có độ phủ gần như đầy đủ. Nhiệt độ, độ ẩm, áp suất, gió và độ che phủ mây có độ phủ khoảng 91,4%. Đây là lý do các mô hình trong từng trạm học được dao động theo giờ khá tốt. Khi đã biết mức nền của trạm, thời tiết có đủ thông tin để giúp mô hình theo dõi lúc tích tụ và lúc khuếch tán.

Nhóm AOD thưa hơn nhiều. AOD theo giờ lấy từ vệ tinh địa tĩnh Himawari, nên dù tần suất quan sát cao vẫn bị mây che; AOT ở pixel trung tâm chỉ có mặt khoảng

11,4% số giờ. Nếu dùng vùng không gian rộng hơn quanh trạm, độ phủ tăng lên khoảng 35% đến 36%. Nếu dùng giá trị AOD gần nhất trong 48 giờ, độ phủ tăng lên khoảng 65,9%. Cách giữ giá trị gần nhất giúp tăng độ phủ, đồng thời làm cho nhiều giờ sử dụng thông tin AOD cũ thay cho quan sát AOD mới.

Bảng 4.1: Một số con số độ phủ quan trọng trong dữ liệu.

Đặc trưng hoặc nhóm	Độ phủ xấp xỉ	Cách đọc
PBLH	100%	Có thể dùng ổn định theo giờ
Nhiệt độ, độ ẩm, áp suất, gió	91,4%	Đủ dày để học dao động thời tiết
Mưa tích lũy và số ngày khô	100%	Có ích cho pha rửa trôi và tích tụ
AOT pixel trung tâm	11,4%	Tín hiệu trực tiếp nhưng rất thưa
AOT trung bình quanh trạm	36,2%	Tốt hơn pixel đơn, vẫn thiếu nhiều
AOT giữ trong 48 giờ	65,9%	Có ích nhưng cần biết tuổi quan sát
NO ₂	60,5%	Bổ sung tín hiệu nguồn giao thông và đô thị
SO ₂	66,4%	Bổ sung tín hiệu công nghiệp và đốt
CO	8,1%	Rất thưa, chỉ nên dùng như thông tin phụ

Bảng 4.1 giúp giải thích một điểm dễ gây hiểu nhầm. Khi mô hình cuối vẫn cho AOD gain đáng kể, điều đó không có nghĩa là AOD một mình giải được PM_{2.5} theo giờ. Nó có nghĩa là AOD có tín hiệu khi xuất hiện, và tín hiệu đó còn hữu ích khi được đưa vào cùng PBLH, độ ẩm, mưa, mùa và PM_{2.5} từ trạm neo. Ngược lại, khi mô hình toàn quốc thất bại ở một số trạm, không thể kết luận rằng vệ tinh vô dụng. Vấn đề là vệ tinh hiện có chưa đủ để nhận ra chắc chắn mức nền của mọi vị trí mới.

Như đã nêu ở Chương 3, các đặc trưng vệ tinh trong vùng đồng bằng sông Hồng vẫn không phủ kín toàn bộ chuỗi giờ. Vì vậy mô hình vùng vẫn cần PM_{2.5} đồng thời từ trạm neo; vệ tinh bổ sung bối cảnh aerosol và nguồn phát thải, còn trạm neo giữ tín hiệu gần mặt đất.

4.3 AOD có tín hiệu nhưng không đủ ở thang giờ

AOD từ vệ tinh là nguồn thông tin quan trọng, nhưng AOD đo cột khí quyển, còn PM2.5 là nồng độ gần mặt đất. Vì vậy, quan hệ giữa AOD và PM2.5 phụ thuộc mạnh vào lớp biên, độ ẩm, gió và loại sol khí [10], [11].

Khi tính trên từng giờ, tương quan Pearson trung bình theo trạm giữa AOD thô và PM2.5 trong dữ liệu này rất yếu, khoảng +0,05. Khi dùng một chỉ số AOD hiệu chỉnh heuristic theo PBLH và độ ẩm, tương quan tăng lên khoảng +0,247. Khi tổng hợp theo tháng, tương quan trung bình theo trạm tăng rõ hơn, khoảng +0,349 với AOD thô và +0,579 với chỉ số AOD hiệu chỉnh heuristic. Phân tích tương quan AOD này là một audit riêng trên bảng `unified_aod_filled.csv` với các dòng AOD cùng giờ; mô hình và các thống kê độ phủ chính của đồ án dùng bảng hợp nhất.

Audit AOD chỉ giữ các thời điểm có AOD thực đo. Khi tổng hợp theo tháng, trung bình AOD phản ánh các giờ có quan sát trời quang hoặc đủ điều kiện truy xuất, trong khi PM2.5 tháng dùng toàn bộ giờ hợp lệ. Chỉ số hiệu chỉnh heuristic chỉ kiểm tra độ nhạy khi thêm PBLH và độ ẩm, chưa phải phép chuyển đổi vật lý đã hiệu chuẩn sang PM2.5. Vì vậy hệ số tương quan theo tháng chủ yếu cho biết mức đồng biến theo mùa, không đo độ chính xác dự báo và không chứng minh rằng AOD có thể thay thế quan trắc PM2.5 mặt đất.

Điều này cho thấy AOD không vô ích. AOD có mang tín hiệu về mức ô nhiễm dài hơn và theo mùa. Nhưng ở thang giờ, AOD đơn lẻ quá thưa và quá nhiễu để quyết định PM2.5 mặt đất. Vì vậy mô hình phải kết hợp AOD với thời tiết, khí vết, chu kỳ thời gian và thông tin từ trạm neo.

4.4 Sản phẩm PM2.5 toàn cầu chưa đủ tốt ở cấp trạm giờ

Đồ án kiểm tra các sản phẩm toàn cầu như GEOS-CF và MERRA-2 tại tọa độ trạm [18], [19]. Kết quả cho thấy chúng chưa đủ tốt để làm dự đoán theo giờ ở Việt Nam.

GEOS-CF có độ lệch dương rất lớn, trung bình khoảng +36,3 $\mu\text{g}/\text{m}^3$ so với quan trắc, tương đương khoảng +221%. Tương quan theo thời gian cũng thấp, trung vị khoảng 0,19. MERRA-2 có bias trung bình theo trạm nhỏ hơn nhiều, khoảng -1,8 $\mu\text{g}/\text{m}^3$, nhưng tương quan thời gian vẫn yếu, trung vị khoảng 0,17.

Nói đơn giản, GEOS-CF sai mạnh về mức, còn MERRA-2 không theo kịp dao động theo giờ. Vì vậy đồ án không dùng các sản phẩm này như lời giải trực tiếp. Chúng chỉ có thể đóng vai trò tham khảo hoặc đặc trưng phụ, không thay thế được mô hình học từ dữ liệu trạm địa phương.

4.5 Dữ liệu có học được dao động theo thời gian tại trạm đã biết

Mô hình học tốt khi trạm đã xuất hiện trong huấn luyện. Trong đánh giá trong từng trạm, dùng đặc trưng thời tiết, vệ tinh và thời gian sau cùng bộ lọc PM2.5, R^2 trung bình đạt khoảng 0,700 và R^2 trung vị đạt khoảng 0,746 trên 40 trạm KK. Đây là kết quả KFold xáo trộn trong từng trạm, nên nó chứng minh dữ liệu có tín hiệu thời gian nhưng không thay thế cho kết quả LOSO hoặc kiểm định ngoài.

Điều này nghĩa là tập đặc trưng không nghèo thông tin. Khi đã biết trạm thuộc bối cảnh nào, mô hình có thể học được dao động theo giờ, theo mùa và theo các điều kiện thời tiết. Vấn đề không nằm ở việc XGBoost quá yếu, hay dữ liệu thời tiết vô dụng. Vấn đề xuất hiện khi phải dự đoán cho một trạm hoàn toàn bị giữ lại.

4.6 Đánh giá bỏ một trạm ra toàn quốc yếu hơn nhiều

Trong đánh giá bỏ một trạm ra, toàn bộ dữ liệu của trạm mục tiêu không được dùng để huấn luyện. Đây là bài toán gần với triển khai hơn: nếu một vị trí chưa có trạm, mô hình có nhận ra mức nền và dao động tại đó hay không?

Kết quả toàn quốc yếu hơn nhiều so với đánh giá trong trạm. Mô hình XGBoost chung, không dùng thông tin tầng ô nhiễm hay trạm neo, đạt R^2 gộp 0,290 nhưng R^2 trung bình theo trạm là -0,139. Điều này cho thấy mô hình vẫn học được một phần dao động lớn trong toàn bộ tập, nhưng kỹ năng không phân bố đều giữa các trạm.

Các cấu hình trong Bảng 4.2 dùng cùng tập 40 trạm KK, cùng giao thức bỏ một trạm ra, cùng bộ lọc PM2.5 và cùng nhóm 68 đặc trưng quan sát được. PM2.5 là biến mục tiêu; PM10 và các khí đo cục bộ tại trạm từ Envisoft không được dùng làm đầu vào. Điểm khác nhau chính là cách tổ chức mô hình hoặc cách chọn expert: một mô hình chung, chia theo vùng địa lý thô, hoặc chia theo tầng ô nhiễm thật để làm trần chẩn đoán.

Bảng 4.2: Chẩn đoán mô hình toàn quốc dưới giao thức bỏ một trạm ra.

Cấu hình	Cách đọc	Triển khai?	R^2 gộp	R^2 TB theo trạm	R^2 trung vị	R^2 dương
Global XGBoost	Một mô hình chung; mỗi fold huấn luyện 39 trạm và giữ 1 trạm trong tập 40	Có	0,290	-0,139	0,016	57,5%
Geographic region	Expert theo Bắc, Trung, Nam	Có	0,309	-0,031	0,019	55,0%

Bảng 4.2 (tiếp)

Cấu hình	Cách đọc	Triển khai?	R^2 gộp	R^2 TB theo trạm	R^2 trung vị	R^2 dương
Oracle true-tier	Expert theo mức nền PM2.5 thật	Không	0,481	0,118	0,128	75,0%

R^2 gộp không đủ để kết luận mô hình dùng được trên bản đồ. Một số trạm ô nhiễm cao và có phương sai lớn có thể kéo R^2 gộp lên, trong khi nhiều trạm còn lại có R^2 thấp hoặc âm. Với mục tiêu ước tính theo vị trí, các chỉ số theo trạm quan trọng hơn.

4.7 Bài học từ chia theo địa lý và mức nền

Chia theo địa lý thô không giải quyết được vấn đề. Geographic region dùng vùng Bắc, Trung, Nam, tức là thông tin có thể biết tại vị trí mới. Cấu hình này tăng nhẹ R^2 gộp so với mô hình global, nhưng R^2 trung bình theo trạm vẫn âm và R^2 trung vị gần bằng 0. Lý do hợp lý là mỗi vùng vẫn còn nhiều kiểu trạm khác nhau: đô thị, công nghiệp, ven biển, nền thấp, nguồn cục bộ. Địa lý thô không tự động đồng nghĩa với cùng mức nền ô nhiễm.

Ngược lại, oracle true-tier tốt hơn rõ rệt. Cấu hình này chọn expert theo mức nền PM2.5 thật của trạm bị giữ lại, nên không triển khai được tại vị trí chưa có trạm. Nó chỉ là trần chẩn đoán. Nhưng chính vì vậy kết quả của nó có ý nghĩa: nếu biết đúng mức nền ô nhiễm của vị trí mới, mô hình có thể cải thiện đáng kể. Vấn đề còn lại là mức nền thật chưa được suy ra ổn định từ các đặc trưng quan sát được trong dữ liệu hiện tại.

Bài học giữ lại là hợp lý: các nguồn thông tin có vai trò khác nhau. Vệ tinh giúp nhận bối cảnh rộng và mùa, thời tiết giúp dao động theo giờ, khí vết giúp nhận nguồn phát thải, còn PM2.5 từ trạm neo giúp neo mức gần mặt đất. Nhưng với mạng trạm toàn quốc còn thưa và không đều, việc nhận ra đúng mức nền cho mọi vị trí mới vẫn chưa đủ chắc.


4.8 Vì sao chọn đồng bằng sông Hồng

Chẩn đoán toàn quốc cho thấy bài toán zero-observation trên toàn Việt Nam còn quá rộng so với mật độ trạm và tập đặc trưng hiện có. Bài toán vùng hẹp hơn, đặc biệt ở vùng ô nhiễm cao, phù hợp hơn với dữ liệu hiện tại và với cách mô hình dùng trạm neo đồng thời.

So sánh điều kiện cho thấy tập toàn quốc có 40 trạm còn vùng đồng bằng sông Hồng có 12 trạm. Vùng đồng bằng sông Hồng không có nhiều trạm hơn. Điểm mạnh của vùng là khoảng cách trung vị tới ba trạm neo gần nhất thấp hơn: 21,6

km so với 27,2 km ở tập toàn quốc. PM2.5 trung vị theo trạm cũng cao hơn, 37,4 $\mu\text{g}/\text{m}^3$ so với 19,3 $\mu\text{g}/\text{m}^3$, và khoảng tứ phân vị tập trung hơn ở vùng ô nhiễm cao. Tỷ lệ giờ có ít nhất ba trạm neo đồng thời gần như đầy đủ, 99,9%.

Hình 4.1 trình bày hai lý do thực nghiệm cho việc chọn phạm vi vùng: khoảng cách đến ba trạm neo gần nhất ngắn hơn và mức PM2.5 trung vị cao hơn so với tập toàn quốc.



Hình 4.1: So sánh bối cảnh toàn quốc sau lọc và đồng bằng sông Hồng.

Đồng bằng sông Hồng là phạm vi chính của mô hình vùng: khu vực này quan trọng về chính sách, có mức ô nhiễm cao, có trạm neo gần hơn khi xét ba trạm gần nhất, và phù hợp với mô hình có điều kiện dựa trên quan trắc PM2.5 đồng thời từ trạm lân cận.

4.9 Kết luận chương

Các thí nghiệm toàn quốc cho thấy một kết quả vừa tích cực vừa hạn chế. Tích cực là dữ liệu có tín hiệu thật: mô hình học được dao động PM2.5 tại trạm đã biết, AOD có tín hiệu dài hạn, và thời tiết có vai trò rõ. Hạn chế là khi giữ toàn bộ một trạm ra ngoài, mô hình quốc gia chưa nhận ra đủ tốt mức nền của vị trí mới.

Phần thực nghiệm tiếp theo đánh giá mô hình đồng bằng sông Hồng, nơi bài toán triển khai được định nghĩa rõ hơn: ước tính PM2.5 tại vị trí mục tiêu trong vùng, có điều kiện là có PM2.5 đồng thời từ các trạm neo lân cận.

CHƯƠNG 5. THÍ NGHIỆM VÙNG ĐỒNG BẰNG SÔNG HỒNG

Chương này trình bày kết quả chính của mô hình vùng đồng bằng sông Hồng. Giao thức đánh giá tập trung vào câu hỏi:

Khi có PM2.5 đồng thời từ các trạm neo trong vùng đồng bằng sông Hồng, mô hình có thể ước tính PM2.5 tại một trạm vùng bị giữ lại hay không?

Bài toán vùng sử dụng điều kiện vận hành rõ ràng: mô hình cần mạng trạm neo hoạt động cùng thời điểm. Điều kiện này phù hợp với dữ liệu hiện có và với nhu cầu ước tính PM2.5 trong vùng ô nhiễm cao nhất của Việt Nam.

5.1 Thiết lập thí nghiệm

Tập vùng gồm 12 trạm KK ở đồng bằng sông Hồng. Dữ liệu đầu vào là `unified_thesis.csv`, sau lọc QC ở cấp từng dòng PM2.5. Trong vùng này có 227.075 quan sát theo giờ.

Đánh giá nội bộ dùng giao thức bỏ một trạm ra. Ở mỗi fold, toàn bộ chuỗi của một trạm được giữ lại để kiểm tra. Các trạm còn lại dùng để huấn luyện, tính base margin theo vùng và tính RFSI. Trạm bị giữ lại không được dùng trong RFSI của chính nó hoặc của trạm khác.

Các cấu hình chính:

- `delta_bm`: dùng đặc trưng vệ tinh, thời tiết, chu kỳ và đặc trưng vật lý, với base margin theo vùng;
- `delta_rfsi`: thêm PM2.5 từ trạm neo lân cận;
- `delta_rfsi_wind`: thêm đặc trưng trạm neo có xét hướng gió;
- `delta_rfsi_regime`: thêm một số đặc trưng đô thị và nguồn phát thải;
- `oracle_bm`: dùng trung bình PM2.5 hậu QC của trạm bị giữ lại theo tháng lịch, gộp toàn bộ các năm, chỉ để đo trần chuẩn đoán.

Mô hình cuối được chọn trước khi xem kiểm định ngoài là `delta_rfsi_wind`.

Cần lưu ý rằng `delta_rfsi_wind` được chọn dựa trên so sánh LOSO nội bộ rồi cũng được báo cáo trên cùng giao thức LOSO đó. Vì vậy kết quả nội bộ có thể có một phần lạc quan do chọn cấu hình. Kiểm định ngoài trên LCS và trạm Đại sứ quán Hoa Kỳ được dùng như bằng chứng độc lập hơn về khả năng chuyển giao.

5.2 Kết quả nội bộ theo giờ

Bảng 5.1 cho thấy RFSI là bước cải thiện chính. Mô hình chỉ dùng base margin vùng và đặc trưng quan sát đạt R^2 gộp 0,2899 và R^2 trung bình theo trạm 0,1806.

Khi thêm RFSI, R^2 gộp tăng lên 0,4161 và R^2 trung bình theo trạm tăng lên 0,2635. Khi thêm thành phần hướng gió, cấu hình `delta_rfsi_wind` đạt kết quả tốt nhất trong các cấu hình triển khai được.

Bảng 5.1: Kết quả bỏ một trạm ra theo giờ trên 12 trạm đồng bằng sông Hồng.


Cấu hình	R^2 gộp	RMSE	MAE	Bias	R^2 TB theo trạm	R^2 trung vị	R^2 dương
Base margin	0,2899	27,16	17,08	-5,723	0,1806	0,2635	75%
+ RFSI	0,4161	24,63	15,26	-3,356	0,2635	0,4153	83%
+ RFSI và gió	0,4233	24,48	15,19	-3,235	0,2709	0,3928	83%
+ Regime	0,3752	25,48	16,11	-4,623	0,2178	0,3097	67%
+ Regime và gió	0,3799	25,38	16,04	-4,695	0,2253	0,3101	67%
Oracle base margin	0,5907	20,62	12,88	-3,117	0,4989	0,5178	100%

Tên trong bảng là tên rút gọn để dễ đọc; mã đầy đủ được ghi trong script và báo cáo kết quả. Cấu hình oracle là trần chẩn đoán và không triển khai được tại vị trí mới.

`delta_rfsi_wind` là mô hình triển khai tốt nhất: R^2 gộp 0,4233, R^2 trung bình theo trạm 0,2709, R^2 trung vị 0,3928 và 83% số trạm có R^2 dương. Sai số trung bình tuyệt đối là 15,19 $\mu\text{g}/\text{m}^3$ và bias là -3,235 $\mu\text{g}/\text{m}^3$. Trong chương này, RFSI được hiểu là nhóm đặc trưng từ PM2.5 trạm neo lân cận, gồm nội suy theo khoảng cách, trạm gần nhất, đầu gió, cuối gió và độ phân tán giữa các trạm neo.


`oracle_bm` cao hơn nhiều, nhưng không được dùng như mô hình cuối. Trong bản chạy cuối, cấu hình này giữ cùng nhóm đặc trưng và cùng định nghĩa RFSI như `delta_rfsi_wind`, chỉ thay base margin bằng trung bình PM2.5 hậu QC của trạm bị giữ lại theo tháng lịch, gộp toàn bộ các năm. Vì vậy khoảng cách giữa `delta_rfsi_wind` và `oracle_bm` cho thấy bài toán ước tính mức nền tại vị trí mới vẫn chưa được giải quyết hoàn toàn.

Hình 5.1 tóm tắt trực quan các chỉ số chính của các cấu hình trong Bảng 5.1.



Hình 5.1: So sánh hiệu năng các cấu hình vùng đồng bằng sông Hồng.

Hình 5.2 kiểm tra kết quả theo từng trạm. Chỉ số theo trạm cho biết RFSI có cải thiện rộng hay chỉ làm tăng chỉ số gộp. RFSI cải thiện phần lớn trạm so với mô hình chỉ dùng base margin vùng, đặc biệt ở các trạm t2 và t3. Trạm t1 duy nhất vẫn là điểm khó: mô hình vùng ô nhiễm cao có xu hướng dự đoán quá cao cho vị trí có mức nền thấp.



Hình 5.2: So sánh R^2 theo từng trạm trong LOSO vùng đồng bằng sông Hồng.

5.3 Kết quả theo ngày

Để kiểm tra xem mô hình có ổn định hơn khi giảm nhiều theo giờ hay không, các dự đoán được tổng hợp theo ngày. Một ngày chỉ được dùng nếu có ít nhất 18 giờ hợp lệ.

Bảng 5.2: Kết quả bỏ một trạm ra theo ngày trên 12 trạm đồng bằng sông Hồng.

Cấu hình	R^2 ngày gộp	RMSE ngày	R^2 TB theo trạm	R^2 trung vị	R^2 dương
Base margin	0,3650	21,91	0,2158	0,3597	75%
+ RFSI	0,4750	19,93	0,2619	0,4973	75%
+ RFSI và gió	0,4911	19,62	0,2835	0,4778	83%
+ Regime	0,4121	21,09	0,1825	0,3513	67%
+ Regime và gió	0,4191	20,96	0,1944	0,3517	67%
Oracle base margin	0,6928	15,24	0,5752	0,6390	100%

Theo ngày, `delta_rfsi_wind` đạt R^2 gộp 0,4911 và R^2 trung bình theo trạm 0,2835. Bảng 5.2 cho thấy việc tổng hợp theo ngày cải thiện R^2 gộp cho hầu hết cấu hình, phù hợp với việc nhiều nhiều tức thời của cảm biến, AOD và thời tiết được làm mượt khi tổng hợp ngày.

5.4 Kết quả theo mức ô nhiễm

Hiệu năng không đều giữa các mức ô nhiễm. Các tầng t1, t2 và t3 được gán theo PM2.5 trung bình sau QC như đã mô tả ở Chương 3. Với `delta_rfsi_wind`, nhóm trạm ô nhiễm cao t3 đạt R^2 trung bình 0,4736. Nhóm t2 đạt 0,1761. Trạm t1 duy nhất có R^2 âm sâu, -1,0664.

Điều này cho thấy mô hình vùng phù hợp nhất với mục tiêu chính: vùng ô nhiễm cao ở miền Bắc. Một trạm sạch hoặc thấp bất thường nằm trong vùng ô nhiễm cao vẫn khó dự đoán. Kết quả này xác định giới hạn của mô hình đối với các trạm có mức nền thấp bất thường.

5.5 Vai trò của các nhóm đặc trưng

Tầm quan trọng đặc trưng được gom theo nhóm để tránh đọc quá mức từng biến riêng lẻ. Gain của XGBoost không chứng minh quan hệ nhân quả, nhưng cho biết nhóm thông tin nào được mô hình dùng nhiều khi giảm sai số.

Ba cấu hình trong Bảng 5.3 được huấn luyện lại trên đủ 12 trạm KK trong vùng. `delta_bm` chưa có RFSI, nên mô hình dựa vào vệ tinh, khí vết, thời tiết và chu kỳ. Trong cấu hình này, nhóm AOD vệ tinh chiếm 28,2% gain, TROPOMI chiếm 14,9%, thời tiết chiếm 15,1%, và nhóm gió phân tán chiếm 13,3%. Các nguồn vệ tinh và thời tiết vì vậy có tín hiệu rõ khi mô hình chưa có PM2.5 từ trạm neo.

Khi thêm RFSI, cấu trúc thông tin thay đổi. Ở `delta_rfsi`, nhóm PM2.5 từ

trạm neo chiếm 56,0% gain. Ở mô hình cuối `delta_rfsi_wind`, nhóm này tăng lên 69,5%. PM2.5 ở các trạm gần đó, cùng thời điểm, là thông tin gần mặt đất nhất và trực tiếp nhất. AOD vệ tinh vẫn còn 15,1% gain trong mô hình cuối, còn khí vết, thời tiết, mưa và chu kỳ thời gian giữ vai trò bổ trợ.


Bảng 5.3 so sánh gain theo nhóm đặc trưng trước và sau khi thêm RFSI, còn Bảng 5.4 rút gọn riêng cho mô hình cuối.

Bảng 5.3: Gain theo nhóm đặc trưng trong ba cấu hình chính.

Nhóm đặc trưng	Base margin	+ RFSI	+ RFSI và gió
PM2.5 trạm neo và RFSI	0,0%	56,0%	69,5%
AOD vệ tinh	28,2%	19,2%	15,1%
Khí vết TROPOMI	14,9%	5,9%	4,1%
Thời tiết	15,1%	6,2%	3,7%
Gió và phân tán	13,3%	3,5%	1,5%
Tương tác vật lý AOD	8,9%	2,6%	1,2%
Chu kỳ thời gian	9,1%	2,4%	1,8%
Tương tác khí	6,4%	1,3%	1,2%
Mưa và số ngày khô	4,2%	2,9%	1,9%

Bảng 5.4: Gain theo nhóm đặc trưng trong mô hình cuối.

Nhóm đặc trưng	Tỷ lệ gain
PM2.5 trạm neo và RFSI	69,5%
AOD vệ tinh	15,1%
Khí vết TROPOMI	4,1%
Thời tiết	3,7%
Mưa và số ngày khô	1,9%
Chu kỳ thời gian	1,8%
Gió và phân tán	1,5%
Tương tác vật lý AOD	1,2%
Tương tác khí	1,2%



Hình 5.3: Tỷ lệ gain theo nhóm đặc trưng trong các cấu hình vùng.

Hình 5.3 trực quan hóa cùng kết quả của Bảng 5.3 và cho thấy RFSI trở thành nhóm thông tin chính khi được đưa vào mô hình.

Kết quả này cho thấy mô hình vùng vẫn dùng tín hiệu vệ tinh, nhất là AOD. Khi có dữ liệu đồng thời từ các trạm neo, thông tin PM2.5 lân cận trở thành nguồn mạnh nhất. Vì vậy phạm vi triển khai của mô hình phụ thuộc vào mạng trạm neo hoạt động cùng thời điểm.

AOD thô ở pixel trung tâm rất thưa, nhưng nhóm AOD của mô hình gồm thêm AOD trung bình quanh trạm, AOD vùng ngoài, thống kê lẫn, giá trị giữ trong 48 giờ và tuổi của quan sát AOD gần nhất. Do đó gain của AOD trong Bảng 5.3 không có nghĩa là mọi giờ đều có quan sát AOD mới. Nó cho thấy mô hình tận dụng tín hiệu aerosol khi có dữ liệu và dùng các biến tuổi quan sát để phân biệt AOD mới với AOD đã cũ.

Phần diễn giải mô hình vùng tập trung vào PM2.5 từ trạm neo, dữ liệu vệ tinh và khí tượng.

5.6 Kiểm định ngoài bằng LCS và trạm Đại sứ quán Hoa Kỳ


Sau khi chọn `delta_rfsi_wind` từ đánh giá nội bộ, mô hình được huấn luyện lại trên cả 12 trạm KK vùng và kiểm định trên các trạm ngoài trong vùng. Có 42 ứng viên kiểm định và cả 42 trạm đều tạo được hàng kiểm định hợp lệ: 41 trạm LCS và trạm Đại sứ quán Hoa Kỳ tại Hà Nội. Với mỗi trạm kiểm định, các đặc trưng vệ tinh, khí tượng và chu kỳ thời gian được trích xuất tại đúng tọa độ của trạm từ cùng bảng hợp nhất, còn RFSI được tính tại tọa độ đó từ các trạm neo KK đồng thời. Các biến gió dùng cho RFSI theo gió cũng lấy từ chính tọa độ trạm kiểm định. PM2.5 của trạm kiểm định chỉ dùng làm giá trị tham chiếu, không đưa vào đầu vào. Chỉ chấm các giờ mà trạm kiểm định có đồng thời PM2.5 và khí tượng riêng.

Kết quả trạm Đại sứ quán tốt: R^2 theo giờ 0,629, RMSE 18,2 $\mu\text{g}/\text{m}^3$ trên 17.995 giờ. Khi tổng hợp ngày, R^2 tăng lên 0,749 với RMSE 11,9 $\mu\text{g}/\text{m}^3$ trên 751 ngày.

Mạng LCS có kết quả không đều hơn, đúng như kỳ vọng với cảm biến chi phí thấp và vị trí rất đa dạng. Trung vị R^2 theo giờ là 0,189, tỷ lệ trạm dương là 63%. Theo ngày, trung vị R^2 là 0,155, tỷ lệ trạm dương là 59%. Trung bình R^2 theo LCS gần 0 và bị kéo xuống bởi một số vị trí khác mạnh với bối cảnh trạm neo, gồm một điểm PM2.5 rất thấp ở Hải Phòng bị dự đoán quá cao và một điểm PM2.5 rất cao ở Hưng Yên bị dự đoán quá thấp.

Bảng 5.5: Kiểm định ngoài trong vùng.

Tập kiểm định	R^2 theo giờ	R^2 theo ngày	Ghi chú
Đại sứ quán Hoa Kỳ Hà Nội	0,629	0,749	Trạm tham chiếu chất lượng cao
LCS, trung vị	0,189	0,155	41 trạm LCS xử lý được
LCS, tỷ lệ R^2 dương	63%	59%	Nhiều trạm có ích, nhưng không đồng đều



Hình 5.4: Phân bố R^2 theo giờ trên mạng kiểm định ngoài.


Bảng 5.5 và Hình 5.4 cho thấy kiểm định ngoài có hai mặt: trạm tham chiếu Đại sứ quán Hoa Kỳ khớp tốt, còn mạng LCS có phân bố rộng hơn và có một số trạm âm rõ rệt.

Kiểm định ngoài này dùng đặc trưng trích xuất tại đúng tọa độ từng trạm, nên đo trực tiếp khả năng chuyển giao của mô hình tại vị trí mới có trạm neo lân cận. Bước còn lại để thành bản đồ vận hành là trích xuất cùng nhóm đặc trưng tại mọi ô lưới, không chỉ tại tọa độ trạm kiểm định.

5.7 Trường hợp thất bại

Trường hợp thất bại rõ nhất là một trạm Hải Phòng có PM2.5 trung bình chỉ $9,3 \mu\text{g}/\text{m}^3$ nhưng mô hình dự đoán cao hơn nhiều, dẫn đến R^2 theo giờ -4,452. Chưa có đủ bằng chứng để quy sai số này cho lỗi dữ liệu. Nó có thể là một vị trí thật sự sạch hơn bối cảnh vùng, hoặc có điều kiện lắp đặt khác với các trạm neo. Dù nguyên nhân là gì, đây là giới hạn quan trọng: mô hình vùng ô nhiễm cao có thể khó với điểm thấp bất thường.

Một thất bại khác đi theo hướng ngược lại. Trạm Hưng Yên Nhà văn hoá thể thôn Hồng Cầu có PM2.5 trung bình $76,0 \mu\text{g}/\text{m}^3$ trong phần kiểm định, nhưng mô hình dự đoán thấp hơn nhiều, với bias $-43,2 \mu\text{g}/\text{m}^3$ và R^2 theo giờ -0,266. Đây là điểm cực trị trong mạng LCS: trong 41 trạm LCS vùng, chỉ trạm này có PM2.5 trung bình vượt $70 \mu\text{g}/\text{m}^3$. Trên toàn chuỗi sau QC, Hồng Cầu có trung vị $56,0 \mu\text{g}/\text{m}^3$, p90 $158,3 \mu\text{g}/\text{m}^3$ và không bị bộ lọc flatline, stuck-low hoặc ngưỡng >500 gấn cờ. Tuy vậy, trạm Như Quỳnh cách khoảng 3,3 km chỉ có PM2.5 trung bình $15,1 \mu\text{g}/\text{m}^3$. Vì vậy Hồng Cầu có thể là một hotspot rất cục bộ, một vấn đề hiệu chuẩn cảm biến, hoặc cả hai. Đề án giữ trạm này trong kiểm định ngoài và xem đây là thất bại thật của mô hình thay vì loại sau khi thấy kết quả.



Hình 5.5: Một số trường hợp thất bại trong kiểm định LCS ngoài.

Hình 5.5 đặt các chuỗi thất bại cạnh nhau để nhấn mạnh rằng sai số ngoài mẫu có thể đến từ cả điểm nền thấp bất thường và hotspot rất cục bộ.

Các trường hợp này cho thấy hiệu năng giảm tại các vị trí có bối cảnh khác xa mạng trạm neo. Khi triển khai bản đồ, cần đi kèm chỉ báo tin cậy hoặc cảnh báo cho các điểm có bối cảnh khác xa trạm neo.

5.8 Kết luận chương

Mô hình đồng bằng sông Hồng đạt kết quả tốt hơn và dễ giải thích hơn mô hình toàn quốc không dùng trạm neo. Kết quả chính là delta_rfsi_wind : R^2 gộp 0,4233 theo giờ, 0,4911 theo ngày, R^2 trung bình theo trạm 0,2709 theo giờ và 0,2835 theo ngày. Kiểm định ngoài cho kết quả tốt tại trạm Đại sứ quán Hoa Kỳ Hà Nội và trung vị dương trên mạng LCS, nhưng cũng cho thấy chuyển giao sang LCS không đồng đều.

Kết quả chính của chương là mô hình cây tăng cường có thể tạo ra ước tính PM2.5 hữu ích trong vùng ô nhiễm cao khi có trạm neo đủ gần. Nguồn thông tin mạnh nhất là PM2.5 đồng thời từ trạm lân cận; AOD, khí vết, thời tiết và chu kỳ thời gian cung cấp bối cảnh bổ trợ. Kết quả áp dụng cho các vị trí trong vùng có trạm neo lân cận hoạt động đồng thời.

CHƯƠNG 6. KẾT LUẬN

Đề án nghiên cứu bài toán ước tính PM_{2.5} theo giờ từ dữ liệu vệ tinh, thời tiết và mạng trạm mặt đất tại Việt Nam. Kết quả cho thấy bài toán toàn quốc tại vị trí chưa có trạm còn bị giới hạn bởi việc mức nền ô nhiễm của vị trí mới chưa được nhận ra ổn định từ các đặc trưng quan sát được. Trong phạm vi đồng bằng sông Hồng, mô hình vùng có điều kiện dùng trạm neo lân cận cho kết quả tốt hơn và dễ giải thích hơn.

6.1 Kết quả chính

Đóng góp đầu tiên của đề án là bộ dữ liệu hợp nhất PM_{2.5}, vệ tinh, thời tiết, mưa, khí vết và đặc trưng tĩnh cho Việt Nam. Bộ dữ liệu gồm 121 trạm, trong đó 40 trạm KK được dùng làm tập phát triển chính và các trạm LCS cùng trạm Đại sứ quán Hoa Kỳ được giữ cho kiểm định ngoài. Bước QC PM_{2.5} loại các chuỗi quan trắc bất thường như chuỗi bằng không, chuỗi đứng yên và chuỗi kẹt ở mức thấp.

Đóng góp thứ hai là chẩn đoán khoảng cách giữa hai bài toán đánh giá. Khi dự đoán tại trạm đã biết, mô hình học được dao động PM_{2.5} khá tốt, với R^2 trung bình khoảng 0,700 trên 40 trạm KK. Khi giữ toàn bộ một trạm ra ngoài, mô hình toàn quốc không dùng trạm neo yếu hơn nhiều. Kết quả này cho thấy khó khăn chính nằm ở việc nhận ra mức nền ô nhiễm của vị trí mới từ các đặc trưng quan sát được.

Đóng góp thứ ba là kết quả vùng đồng bằng sông Hồng. Mô hình cuối `delta_rf` `si` `wind` dùng XGBoost `gbtree`, base margin theo vùng, RFSI và RFSI có xét hướng gió. Trong đánh giá bỏ một trạm ra trên 12 trạm KK vùng, mô hình đạt R^2 gộp 0,4233 theo giờ và 0,4911 theo ngày; R^2 trung bình theo trạm là 0,2709 theo giờ và 0,2835 theo ngày. Kiểm định ngoài dùng đặc trưng trích xuất tại đúng tọa độ trạm cho kết quả tốt tại trạm Đại sứ quán Hoa Kỳ Hà Nội, với R^2 0,629 theo giờ và 0,749 theo ngày. Trên 41 trạm LCS vùng, trung vị R^2 là 0,189 theo giờ và 0,155 theo ngày.

6.2 Ý nghĩa của kết quả

Phân tích gain cho thấy trong mô hình cuối, PM_{2.5} từ trạm neo và RFSI chiếm 69,5% gain. AOD vệ tinh chiếm 15,1%; khí vết, thời tiết, mưa và chu kỳ thời gian đóng vai trò hỗ trợ. Mô hình có ích vì nó kết hợp thông tin mặt đất gần thời điểm dự đoán với các tín hiệu bối cảnh từ vệ tinh và thời tiết.

Điều này dẫn đến cách diễn giải thực tế: mô hình phù hợp cho kịch bản có mạng trạm neo hoạt động, ví dụ ước tính PM_{2.5} tại các điểm giữa các trạm trong đồng bằng sông Hồng. Các kết quả hiện tại thiết lập khả năng ước tính có điều kiện trong đồng bằng sông Hồng; chúng chưa đánh giá đầy đủ khả năng lập bản đồ trên toàn

quốc tại các vị trí không có trạm neo.

Các kết quả này cần được gắn với đúng giao thức đánh giá. Kết quả trong từng trạm cho biết dữ liệu có tín hiệu thời gian. Kết quả bỏ một trạm ra cho biết khả năng suy ra vị trí mới. Kết quả oracle chỉ là trần chẩn đoán. Kết quả LCS là kiểm định ngoài quan trọng, dùng đặc trưng tại đúng tọa độ trạm, nhưng vẫn chưa thay thế cho kiểm định trên lưới điểm dày phủ toàn vùng.

6.3 Giới hạn

Giới hạn thứ nhất là phạm vi không gian. Đồng bằng sông Hồng là vùng ô nhiễm cao và có trạm neo gần hơn khi xét ba trạm gần nhất. Kết quả vùng không tự động mở rộng cho miền Trung, miền Nam hoặc các vùng ít trạm hơn.

Giới hạn thứ hai là các vị trí có mức nền khác mạnh với trạm neo lân cận. Một trạm Hải Phòng có PM2.5 trung bình chỉ $9,3 \mu\text{g}/\text{m}^3$ bị dự đoán cao hơn nhiều và có R^2 âm sâu. Ngược lại, trạm Hưng Yên Hồng Cầu có PM2.5 rất cao nhưng bị dự đoán thấp. Đây là các thất bại thật của mô hình vùng nếu không có thêm bằng chứng cho thấy trạm lỗi dữ liệu. Khi dùng mô hình, cần xem các điểm thấp bất thường, cao bất thường hoặc khác xa trạm neo là vùng rủi ro.

Giới hạn thứ ba là kiểm định ngoài mới chỉ thực hiện tại đúng tọa độ các trạm LCS và Đại sứ quán, chưa phải trên một lưới điểm dày. Các đặc trưng vệ tinh, khí tượng, chu kỳ thời gian và RFSI đã được tính tại đúng tọa độ từng trạm kiểm định, nên kết quả LCS đo trực tiếp khả năng chuyển giao tại vị trí mới có trạm neo lân cận. Tuy vậy, để thành bản đồ vận hành cần trích xuất cùng nhóm đặc trưng tại mọi ô lưới và kiểm tra thêm ở các vị trí xa trạm neo hơn.

Giới hạn thứ tư là dữ liệu vệ tinh AOD bị thừa do mây. AOD có tín hiệu, nhưng ở thang giờ tín hiệu yếu hơn nhiều so với khi tổng hợp theo tháng. Điều này làm cho AOD khó trở thành nguồn chính cho dự đoán PM2.5 theo giờ nếu không có trạm neo.

6.4 Hướng phát triển

Hướng phát triển đầu tiên là mở rộng việc trích xuất đặc trưng từ tọa độ trạm sang một lưới điểm dày phủ toàn vùng. Kiểm định ngoài hiện đã dùng đặc trưng tại đúng tọa độ trạm LCS và Đại sứ quán; bước tiếp theo là sinh cùng nhóm đặc trưng cho mọi ô lưới để biến mô hình vùng thành bản đồ vận hành và kiểm tra ở những vị trí xa trạm neo hơn.

Hướng thứ hai là đưa các LCS đã được hiệu chỉnh vào làm trạm neo bổ sung. Nếu LCS đủ ổn định sau hiệu chỉnh, chúng có thể làm dày mạng quan trắc và cải thiện RFSI, đặc biệt ở những khu vực thiếu trạm KK.

Hướng thứ ba là xây dựng mô hình vùng cho các vùng ô nhiễm khác. Mỗi vùng có thể có mức nền, mùa ô nhiễm, nguồn phát thải và điều kiện thời tiết khác nhau. Cách tiếp cận theo vùng tạo điều kiện đánh giá rõ hơn sự phù hợp giữa mật độ trạm neo, mức nền ô nhiễm và khả năng chuyển giao của mô hình.

Hướng thứ tư là cải thiện ước tính mức nền ô nhiễm tại vị trí mới. Đây là giới hạn lớn nhất của mô hình toàn quốc. Các nguồn có thể giúp gồm sử dụng đất, kiểm kê phát thải, ánh sáng đêm, giao thông, dân cư, AOD dài hạn và khí vết dài hạn.

Một hướng thực tế hơn trong ngắn hạn là tách bài toán thành nhiều vùng. Đồng bằng sông Hồng là vùng đầu tiên vì ô nhiễm cao và có đủ trạm để kiểm tra. Các vùng khác có thể được xây dựng theo cùng khung: trước hết kiểm tra chất lượng dữ liệu, sau đó đánh giá trong trạm, đánh giá bỏ một trạm ra, kiểm tra khoảng cách đến trạm neo, rồi mới quyết định mô hình vùng có đủ đáng tin hay không.

6.5 Kết luận chung

Đồ án cho thấy việc đánh giá PM2.5 bằng học máy cần tách rõ hai câu hỏi. Nếu trạm đã xuất hiện trong huấn luyện, mô hình có thể học dao động theo thời gian khá tốt. Nếu trạm hoàn toàn bị giữ lại, khó khăn lớn nhất là nhận ra mức nền ô nhiễm của vị trí đó. Vì vậy, một mô hình toàn quốc nhìn ổn theo R^2 gộp vẫn có thể chưa đủ tốt theo từng trạm.

Trong phạm vi đồng bằng sông Hồng, khi có dữ liệu PM2.5 đồng thời từ trạm neo lân cận, mô hình `delta_rfsi_wind` cho kết quả tốt và có thể giải thích được. Kết quả chính của nghiên cứu là mô hình vùng có điều kiện triển khai rõ ràng, áp dụng cho các vị trí trong đồng bằng sông Hồng có dữ liệu PM2.5 đồng thời từ trạm neo lân cận.

TÀI LIỆU THAM KHẢO

- [1] World Health Organization, *Who global air quality guidelines: Particulate matter (pm_{2.5} and pm₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*, World Health Organization, 2021. [Online]. Available: <https://www.who.int/publications/i/item/9789240034228>
- [2] GBD 2019 Risk Factors Collaborators, *Global burden of 87 risk factors in 204 countries and territories, 1990–2019: A systematic analysis for the global burden of disease study 2019*, *The Lancet*, 396(10258), 1223–1249, 2020. [Online]. Available: [https://doi.org/10.1016/S0140-6736\(20\)30752-2](https://doi.org/10.1016/S0140-6736(20)30752-2)
- [3] IQAir. “2024 world air quality report: Region and city pm_{2.5} ranking,” IQAir, Accessed: May 30, 2026. [Online]. Available: <https://www.iqair.com/newsroom/waqr-2024-pr>
- [4] VietnamPlus. “Vietnam to have 98 more automatic air quality monitoring stations by 2030,” Vietnam News Agency (VietnamPlus), Accessed: May 30, 2026. [Online]. Available: <https://en.vietnamplus.vn/vietnam-to-have-98-more-automatic-air-quality-monitoring-stations-by-2030-post282695.vnp>
- [5] A. Lyapustin, Y. Wang, S. Korkin, and D. Huang, “Modis collection 6 maiaac algorithm,” *Atmospheric Measurement Techniques*, 11(10), 5741–5765, 2018. [Online]. Available: <https://doi.org/10.5194/amt-11-5741-2018>
- [6] G. Abad, *Sentinel-5p tropomi level 2 products: No₂, hcho, co and so₂ [data set]*, European Space Agency / Copernicus, 2018. [Online]. Available: <https://doi.org/10.5270/S5P-bj3nry0>
- [7] Earth Observation Group, *Viirs/npp day/night band annual composites (vnl v2) [data set]*, Payne Institute for Public Policy, Colorado School of Mines, 2021. [Online]. Available: <https://eogdata.mines.edu/products/vnl/>
- [8] Copernicus Climate Change Service (C3S), *Era5 hourly data on single levels from 1940 to present [data set]*, Copernicus Climate Change Service (C3S) Climate Data Store (CDS), 2023. [Online]. Available: <https://doi.org/10.24381/cds.adbb2d47>
- [9] G. J. Huffman, E. F. Stocker, D. T. Bolvin, E. J. Nelkin, and J. Tan, “Gpm imerg final precipitation l3 half hourly 0.1 degree × 0.1 degree v06 [data set],” *Goddard Earth Sciences Data and Information Services Center (GES*

- DISC), 2019. [Online]. Available: <https://doi.org/10.5067/GPM/IMERG/3B-HH/06>
- [10] Q. Di et al., “An ensemble-based model of pm2.5 concentration across the contiguous united states with high spatiotemporal resolution,” *Environment International*, 130, 104909, 2019. [Online]. Available: <https://doi.org/10.1016/j.envint.2019.104909>
- [11] J. Wei et al., “Improved 1 km resolution pm2.5 estimates across china using enhanced space-time extremely randomized trees,” *Atmospheric Chemistry and Physics*, 20(6), 3273–3289, 2020. [Online]. Available: <https://doi.org/10.5194/acp-20-3273-2020>
- [12] T. X. Ngo, H. V. Pham, H. D. T. Phan, A. T. N. Nguyen, H. T. To, and T. T. N. Nguyen, “A daily and complete pm2.5 dataset derived from space observations for vietnam from 2012 to 2020,” *Science of the Total Environment*, 857(Pt 3), 159537, 2023. [Online]. Available: <https://doi.org/10.1016/j.scitotenv.2022.159537>
- [13] T. Chen and C. Guestrin, *Xgboost: A scalable tree boosting system*, In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (pp. 785–794), 2016. [Online]. Available: <https://doi.org/10.1145/2939672.2939785>
- [14] K. Bessho et al., “An introduction to himawari-8/9–japan’s new-generation geostationary meteorological satellites,” *Journal of the Meteorological Society of Japan. Ser. II*, 94(2), 151–183, 2016. [Online]. Available: <https://doi.org/10.2151/jmsj.2016-009>
- [15] A. Lyapustin and Y. Wang, *Modis/terra+aqua land aerosol optical depth daily l2g global 1 km sin grid v061 (mcd19a2) [data set]*, NASA Land Processes Distributed Active Archive Center (LP DAAC), 2022. [Online]. Available: <https://doi.org/10.5067/MODIS/MCD19A2.061>
- [16] J. Chen et al., “A comparison of linear regression, regularization, and machine learning algorithms to develop europe-wide spatial models of fine particles and nitrogen dioxide,” *Environment International*, 130, 104934, 2019. [Online]. Available: <https://doi.org/10.1016/j.envint.2019.104934>
- [17] P. Gupta et al., *Machine learning algorithm for estimating surface pm2.5 in thailand*, *Aerosol and Air Quality Research*, 21(5), 210105, 2021. [Online]. Available: <https://doi.org/10.4209/aaqr.210105>
- [18] Global Modeling and Assimilation Office (GMAO), *Geos composition forecast (geos-cf) system, version 1.0 [data set]*, NASA Global Modeling and

- Assimilation Office, 2020. [Online]. Available: https://gmao.gsfc.nasa.gov/weather_prediction/GEOS-CF/
- [19] Global Modeling and Assimilation Office (GMAO), “Merra-2 tavg1-2d-aer-nx: 2d, 1-hourly, time-averaged, single-level, assimilation, aerosol diagnostics v5.12.4 [data set],” *Goddard Earth Sciences Data and Information Services Center (GES DISC)*, 2015. [Online]. Available: <https://doi.org/10.5067/KLICLTZ8EM9D>

PHỤ LỤC

A. DỮ LIỆU VÀ ĐẶC TRƯNG

Phụ lục này cung cấp các bảng tham chiếu bổ sung cho bộ dữ liệu và đặc trưng được sử dụng trong đồ án.

A.1 Danh sách trạm quan trắc

Bảng dưới đây liệt kê 40 trạm quan trắc chất lượng không khí (KK) trong tập phát triển. Các thí nghiệm quốc gia dùng đủ 40 trạm theo giao thức bỏ một trạm ra; kiểm soát chất lượng PM2.5 được áp dụng ở cấp từng dòng dữ liệu.

Bảng A.1: Danh sách trạm KK trong tập phát triển

Tên trạm	Vĩ độ	Kinh độ	Vùng	Tier	Phủ PM2.5
Bình Định Khuôn viên Cây xanh gần cầu chui đường Hoa Lư - TP. Quy Nhơn (KK)	13.79	109.220	Central	t1	96%
Lâm Đồng Vườn hoa - đối diện THCS Lam Sơn - Phường 6 - TP Đà Lạt (KK)	11.95	108.430	Central	t1	93%
Quảng Nam Tiếp giáp Đ. Hùng Vương - KDC Đ. Hồ Xuân Hương (KK)	15.56	108.487	Central	t1	94%
Quảng Ngãi UBND P. Nguyễn Nghiêm - TP Quảng Ngãi (KK)	15.12	108.804	Central	t1	93%
Đà Nẵng 41 đường Lê Duẩn (KK)	16.07	108.217	Central	t1	77%
Đà Nẵng Khuôn viên trường ĐH sư phạm Đà Nẵng (KK)	16.06	108.159	Central	t1	96%
Gia Lai KCN Trà Đa - Tp Pleiku (KK)	14.02	108.035	Central	t2	70%
Bình Định huyện Tuy Phước (KK)	13.76	109.220	Central	t3	67%
Ninh Thuận Công viên (bến xe cũ) - Đ. Thống Nhất - P. Thanh Sơn - TP Phan Rang (KK)	11.57	108.992	Central	t3	71%
Đà Nẵng Phạm Hùng (KK)	16.00	108.207	Central	t3	76%
Bắc Ninh Khu liên cơ Thuận Thành - thị trấn Hồ (KK)	21.03	106.034	North	t1	72%
Bắc Ninh TT Quan trắc - phường Suối Hoa - TP Bắc Ninh (KK)	21.19	106.074	North	t1	56%

Tên trạm	Vĩ độ	Kinh độ	Vùng	Tier	Phủ PM2.5
Bắc Ninh UBND xã Cao Đức - Gia Bình (KK)	21.08	106.281	North	t1	69%
Hà Nam Công Viên Nam Cao - P.Quang Trung - TP. Phủ Lý (KK)	20.54	105.916	North	t1	95%
Hà Nội 556 Nguyễn Văn Cừ (KK)	21.05	105.883	North	t1	94%
Hà Nội Công viên Nhân Chính - Khuất Duy Tiến (KK)	21.00	105.795	North	t1	96%
Hà Nội ĐHBK cổng Parabol đường Giải Phóng (KK)	21.01	105.842	North	t1	97%
Hưng Yên số 437 Nguyễn Văn Linh - Tp Hưng Yên (KK)	20.66	106.059	North	t1	92%
Hải Dương UBND TP. Hải Dương - 106 Đường Trần Hưng Đạo (KK)	20.94	106.336	North	t1	95%
Phú Thọ đường Hùng Vương - Tp Việt Trì (KK)	21.34	105.367	North	t1	91%
Thái Bình Cầu Thái Bình - Đ. Trần Thái Tông - P. Bò Xuyên - TP Thái Bình (KK)	20.46	106.344	North	t1	95%
Thái Nguyên Sân vận động Gang thép - P Trung Thành - TP Thái Nguyên (KK)	21.54	105.872	North	t2	89%
Bắc Ninh UBND xã Xuân Lâm - Thuận Thành (KK)	21.02	106.017	North	t3	51%
Quảng Ninh Gần KCN Cái Lân (KK)	20.97	107.044	North	t3	51%
Quảng Ninh Km11 - Minh Thành (KK)	21.01	106.859	North	t3	57%
Quảng Ninh Nhuệ Hồ - Đông Triều (KK)	21.07	106.556	North	t3	52%
Quảng Ninh Nhà máy tuyển than Nam Cầu Trắng - Hạ Long (KK)	20.95	107.131	North	t3	62%
Quảng Ninh Phường Cẩm Thịnh - Cẩm Phả (KK)	21.01	107.344	North	t3	97%
Quảng Ninh Trung tâm văn hóa thể thao Cẩm Phả, đường Trần Phú, phường Cẩm Trung (KK)	21.01	107.274	North	t3	60%

Tên trạm	Vĩ độ	Kinh độ	Vùng	Tier	Phủ PM2.5
Quảng Ninh UBND TP Uông Bí (KK)	21.04	106.764	North	t3	57%
Thái Bình xã Thái Thọ, huyện Thái Thụy (KK)	20.46	106.517	North	t3	80%
Bình Dương số 593 Đại lộ Bình Dương, P. Hiệp Thành (KK)	10.99	106.658	South	t1	96%
HCM Khu Liên cơ quan Bộ Tài Nguyên và Môi Trường - số 20 Đ. Lý Chính Thắng (KK)	10.78	106.683	South	t1	98%
HCM Đ. Lê Hữu Kiều - P. Bình Trưng Tây - Quận 2 (Ngã ba Lê Hữu Kiều và Trương Văn Bang) (KK)	10.78	106.753	South	t1	94%
Trà Vinh xã Dân Thành, TX Duyên Hải (KK)	9.60	106.520	South	t2	97%
Tây Ninh Thị xã Trảng Bàng (KK)	11.03	106.356	South	t2	73%
Long An UBND Tp Tân An - 76 Hùng Vương - P.2 (KK)	10.54	106.405	South	t3	96%
Sóc Trăng Sở TNMT - 16 Hùng Vương, P.6, Tp. Sóc Trăng (KK)	9.61	105.968	South	t3	52%
Trà Vinh xã Đông Hải, huyện Duyên Hải (KK)	9.58	106.488	South	t3	64%
Vũng Tàu Đ. Huyện Trần Công Chúa - Phường 8 - TP Vũng Tàu	10.50	107.274	South	t3	97%

A.2 Các cột nền trong bảng hợp nhất

Bảng dưới đây liệt kê 71 cột nền trong `unified_thesis.csv`, phân loại theo nguồn dữ liệu. PM2.5 trong bảng này là biến mục tiêu dùng để huấn luyện và đánh giá, không phải đặc trưng đầu vào của mô hình. Tỷ lệ phủ trong bảng được tính trên 40 trạm KK của tập phát triển; Bảng 3.1 trong thân đồ án tính trên toàn bộ bảng hợp nhất 121 trạm, nên tỷ lệ ở đó thấp hơn (ví dụ AOT trung bình quanh trạm 51% so với 36%).

Bảng A.2: Các cột nền trong bảng hợp nhất

Cột	Loại	Nguồn	Phủ (%)
elevation_m	static	DEM	100%

Cột	Loại	Nguồn	Phủ (%)
slope_deg	static	DEM	100%
aspect_sin	static	DEM	100%
aspect_cos	static	DEM	100%
latitude	static	metadata	100%
longitude	static	metadata	100%
PM2.5	dynamic	Envisoft	87%
PM10	dynamic	Envisoft	86%
Temperature_final	dynamic	Envisoft+OpenMeteo	100%
Humidity_final	dynamic	Envisoft+OpenMeteo	100%
Pressure_final	dynamic	Envisoft+OpenMeteo	100%
WS_om	dynamic	OpenMeteo	100%
WD_om	dynamic	OpenMeteo	100%
WS_local	dynamic	Envisoft	89%
WD_local	dynamic	Envisoft	88%
PBLH	dynamic	OpenMeteo	100%
AOT	dynamic	Himawari	15%
AOT_mean	dynamic	Himawari	51%
AOT_spatial_std	dynamic	Himawari	46%
AOT_inner_mean	dynamic	Himawari	41%
AOT_outer_mean	dynamic	Himawari	50%
Uncertainty	dynamic	Himawari	15%
AE	dynamic	Himawari	16%
SSA	dynamic	Himawari	16%
RF	dynamic	Himawari	15%
precip_mm	dynamic	GPM	99%
precip_rate	dynamic	GPM	81%
NO2	dynamic	Envisoft	74%
O3	dynamic	Envisoft	78%
SO2	dynamic	Envisoft	85%
CO	dynamic	Envisoft	10%
AOT_grad_ns	derived	derived-spatial	31%
AOT_grad_ew	derived	derived-spatial	34%
AOT_grad_mag	derived	derived-spatial	24%
AOT_grad_dir	derived	derived-spatial	24%
AOT_local_vs_regional	derived	derived-spatial	40%
AOT_lag_1h	derived	derived-temporal	15%
AOT_lag_3h	derived	derived-temporal	15%
AOT_lag_6h	derived	derived-temporal	15%
AOT_rolling_mean_6h	derived	derived-temporal	30%

Cột	Loại	Nguồn	Phủ (%)
AOT_rolling_mean_24h	derived	derived-temporal	62%
hours_since_valid_AOT	derived	derived-temporal	100%
AOT_ffill_48h	derived	derived-temporal	75%
RH_factor	derived	derived-physics	100%
AOD_physics	derived	derived-physics	15%
hrs_since_rain	derived	derived-precip	100%
rain_sum_24h	derived	derived-precip	100%
rain_sum_48h	derived	derived-precip	100%
rain_days_7d	derived	derived-precip	100%
consecutive_dry_days	derived	derived-precip	100%
wind_u	derived	derived-met	100%
wind_v	derived	derived-met	100%
wind_dir_sin	derived	derived-met	100%
wind_dir_cos	derived	derived-met	100%
wind_u_local	derived	derived-met	86%
wind_v_local	derived	derived-met	86%
wind_dir_sin_local	derived	derived-met	88%
wind_dir_cos_local	derived	derived-met	88%
VC	derived	derived-met	100%
dT_6h	derived	derived-met	100%
dRH_6h	derived	derived-met	100%
dWS_6h	derived	derived-met	100%
dP_6h	derived	derived-met	100%
hour_sin	derived	derived-temporal	100%
hour_cos	derived	derived-temporal	100%
month_sin	derived	derived-temporal	100%
month_cos	derived	derived-temporal	100%
day_of_year_sin	derived	derived-temporal	100%
day_of_year_cos	derived	derived-temporal	100%
elev_x_PBLH	derived	derived- interaction	100%
elev_x_hour_sin	derived	derived- interaction	100%

A.3 Đặc trưng RFSI sinh trong từng fold

Các cột RFSI không nằm sẵn trong `feature_list.csv`. Chúng được tính trong script thí nghiệm vùng từ PM2.5 đồng thời của các trạm neo lân cận. Trong đánh giá bỏ một trạm ra, trạm đang được kiểm tra luôn bị loại khỏi nhóm neo trước

khi tính các đặc trưng này.

Bảng A.3: Đặc trưng RFSI dùng trong mô hình vùng

Đặc trưng	Ý nghĩa
PM25_nn_idw	Nội suy PM2.5 theo nghịch đảo khoảng cách từ các trạm neo cùng thời điểm
PM25_nn1	PM2.5 của trạm neo gần nhất
PM25_nn2	PM2.5 của trạm neo gần thứ hai
PM25_nn3	PM2.5 của trạm neo gần thứ ba
PM25_upwind_idw	Nội suy PM2.5 từ các trạm nằm gần hướng đầu gió
PM25_downwind_idw	Nội suy PM2.5 từ các trạm nằm gần hướng cuối gió
PM25_wind_spread	Chênh lệch giữa PM2.5 đầu gió và cuối gió
PM25_neighbor_spread	Độ phân tán PM2.5 giữa các trạm neo lân cận

A.4 Google Earth Engine scripts

Các script Google Earth Engine được dùng để trích xuất dữ liệu vệ tinh và khí vết tại tọa độ trạm:

1. **MAIAC AOD:** AOD MODIS tại pixel trung tâm và thống kê vùng lân cận.
2. **TROPOMI:** NO₂, SO₂, CO và HCHO theo ngày.
3. **MODIS LST:** nhiệt độ bề mặt ngày và đêm.
4. **GEOS-CF / MERRA-2:** sản phẩm mô hình và tái phân tích khí quyển dùng cho đánh giá tham chiếu, không dùng làm mô hình cuối.
5. **Himawari AOD:** nguồn AOD tần suất cao có trong bảng hợp nhất và được dùng để kiểm tra, so sánh với MODIS trong các nhánh phân tích nguồn AOD. Mô hình vùng cuối vẫn ưu tiên các đặc trưng AOD đã được chuẩn hóa và thống nhất trong pipeline cuối.

Các biến HCHO trong mô hình vùng được tạo trong `exp_red_river_delta.py` từ bảng GEE theo ngày, gồm anomaly, thống kê lần 30 ngày và một số tương tác với điều kiện mặt đất. Vì vậy HCHO có thể không xuất hiện như một cột nền riêng trong `feature_list.csv`.

B. CẤU HÌNH THÍ NGHIỆM

Phụ lục này tóm tắt chuỗi script chính trong gói mã nguồn nộp kèm và môi trường để chạy lại. Mã nguồn được tổ chức theo bốn giai đoạn: thu thập dữ liệu (01_collection), xử lý và kiểm soát chất lượng (02_processing), xây dựng đặc trưng (03_features) và thí nghiệm mô hình (04_experiments). Cột Script ghi tên tệp chính hoặc thư mục chứa nhóm script tương ứng.

Bảng B.1: Chuỗi script chính của đề án

Bước	Mục đích	Script	Kết quả chính
1	Thu thập dữ liệu trạm và vệ tinh	01_collection/	dữ liệu thô theo trạm
2	Dựng dữ liệu hợp nhất	build_unified.py	unified_thesis.csv
3	Lọc chất lượng PM2.5	pm25_qc.py	mặt nạ QC theo từng dòng
4	Tương quan AOD và PM2.5	aod_pm25_correlation_paper.py	phân tích Mục 4.3
5	Trần dự đoán trong từng trạm	within_station_predictability.py	kết quả Mục 4.5
6	Đánh giá sản phẩm PM2.5 toàn cầu	exp_satellite_products.py	so sánh Mục 4.4
7	Chẩn đoán LOSO toàn quốc	exp_national_loso_diagnostic.py	Bảng 4.2
8	Mô hình vùng ĐBSH và kiểm định ngoài	exp_red_river_delta.py	kết quả Chương 5

Bước 1 và Bước 2 tạo dữ liệu đầu vào cho pipeline. Các script phân tích và thí nghiệm ở các bước sau sử dụng các bảng hợp nhất hoặc tệp xuất phù hợp với từng mục đích. Bộ lọc chất lượng PM2.5 trong `pm25_qc.py` được dùng chung cho các phân tích có dữ liệu PM2.5 mặt đất. Kết quả số và hình do mỗi script sinh ra là cơ sở cho các bảng và hình tương ứng trong Chương 4 và Chương 5; ví dụ Bước 7 tạo chẩn đoán toàn quốc ở Bảng 4.2, còn Bước 8 tạo kết quả mô hình vùng và kiểm định ngoài ở Chương 5.

B.1 Môi trường tái lập

Các kết quả được tạo bằng Python trên Windows, với các phiên bản chính:

- Python 3.10;
- pandas 2.3.3;
- numpy 2.2.6;

- scikit-learn 1.7.2;
- XGBoost 3.2.0;
- matplotlib 3.10.6.

Tệp `requirements.txt` kèm theo gói mã nguồn liệt kê các gói Python cần thiết. Để chạy lại, cài môi trường bằng `pip install -r requirements.txt` rồi chạy các script theo thứ tự trong Bảng B.1.